

Master Data Dictionary

Dictionnaire de données unifié — Toutes sources

DOCUMENT TECHNIQUE

Mémoire de Master

Prédiction de la fenêtre de récolte par Machine Learning

Blé d'hiver · Centre-Val de Loire · France

Université Indrashil — 2025

Encadrants : Dr. Vishvjit Thakar, Dr. Doreid Ammar

Version 1.0 — Document de référence

Avant-propos

À qui s'adresse ce document ?

Le **Master Data Dictionary** est le document de référence technique du projet. Il regroupe en un seul endroit la description complète et précise de **toutes les variables** de toutes les sources de données utilisées.

Il s'adresse à :

-  **Les développeurs / data scientists** qui vont manipuler les données pour construire les modèles ML
-  **Les chercheurs** qui veulent comprendre exactement ce que représente chaque colonne
-  **Les analystes** qui veulent vérifier les unités, les plages de valeurs, les conventions
-  **Les rédacteurs** du mémoire qui ont besoin de citations précises
-  **Les futurs lecteurs** du projet (ou de sa réplication) qui veulent recréer les données

Prérequis : ce document suppose que tu as déjà lu l'**Introduction Agronomique** (document pédagogique séparé). Si certains concepts ne te sont pas familiers (NDVI, BBCH, GDD, SAR, etc.), réfère-toi à ce document d'introduction.

Structure du document

PARTIE I — Vue d'ensemble

1. Objectif du projet et architecture des données
2. Conventions globales (nommage, unités, formats)
3. Schéma de fusion des 6 sources
4. Clés de jointure et règles de jointure

PARTIE II — Description par source

5. Source 1 — CéréObs (cible : dates de récolte)
6. Source 2 — RPG (registre parcellaire)
7. Source 3 — NASA POWER (météo journalière)
8. Source 4 — SoilGrids (propriétés du sol)
9. Source 5 — Sentinel-2 (indices végétation)
10. Source 6 — Sentinel-1 SAR (rétrodiffusion radar)

PARTIE III — Schéma maître et features dérivées

11. Schéma cible du master dataset
12. Features dérivées prévues
13. Variables de qualité et flags

PARTIE IV — Annexes

14. Codes erreurs et valeurs spéciales (NaN, -9999, etc.)
15. Index alphabétique de toutes les colonnes
16. Liens entre datasets Kaggle publics

Notation

Dans ce document, on utilise les conventions suivantes pour caractériser les colonnes :

CLÉ Identifiant primaire ou de jointure **META** Métadonnée (temps, qualité, source) **FEATURE** Variable prédictrice du modèle **TARGET** Variable cible à prédire **DÉRIVÉ** Calculé à partir d'autres colonnes

PARTIE I — Vue d'ensemble

1. Objectif du projet et architecture des données

1.1 Objectif

Objectif : prédire la **fenêtre optimale de récolte** du blé d'hiver à l'échelle de la parcelle agricole, à partir de données de télédétection satellite, de météo et de propriétés du sol. La cible est la date de "récolte 50%" publiée annuellement par Céré'Obs (FranceAgriMer).

1.2 Périmètre

Dimension	Valeur
Culture	Blé tendre d'hiver (<i>Triticum aestivum</i> L.)
Zone géographique	Région Centre-Val de Loire (CVL), France métropolitaine
Départements couverts	6 (Eure-et-Loir 28, Loiret 45, Loir-et-Cher 41, Indre-et-Loire 37, Cher 18, Indre 36)
Période d'étude	2020 → 2024 (5 campagnes agricoles)
Nombre de parcelles	1 500 (300/an × 5 ans)
Taille minimale par parcelle	1 hectare

1.3 Les 6 sources de données

Source	Type	Fournisseur	Rôle dans le projet
Céré'Obs	Phénologie agricole	FranceAgriMer + Arvalis	🎯 Cible (target) : date de récolte 50% régionale
RPG	Cadastre agricole	IGN + Ministère Agriculture	📍 Identification et géolocalisation des parcelles
NASA POWER	Météo journalière	NASA Langley Research Center	☀️ Variables climatiques (T°, pluie, ET0, GDD)
SoilGrids	Propriétés du sol	ISRIC World Soil Information	🪨 Texture, hydraulique, fertilité du sol
Sentinel-2	Optique satellite	ESA (Copernicus)	🌿 Indices végétation NDVI/EVI/NDWI
Sentinel-1 SAR	Radar satellite	ESA (Copernicus)	📡 Rétrodiffusion VV/VH (tout-temps)

1.4 Diagramme d'architecture des données




Figure 1.1 — Architecture de bout en bout : 6 sources → 6 datasets raw publics sur Kaggle → features dérivées par parcelle-année → master dataset final prêt pour le ML.

2. Conventions globales

2.1 Conventions de nommage des colonnes

Toutes les colonnes du projet suivent les conventions suivantes :

Convention	Règle	Exemple
Casse	snake_case (minuscules + underscores)	peak_ndvi
Anglais	Noms en anglais (lisibles internationalement)	harvest_doy
Préfixes par source	Optionnel selon contexte	s2_ , s1_ , soil_ , meteo_
Suffixes statistiques	_median, _mean, _max, _min, _std	ndvi_median
Profondeurs sol	_0_5, _5_15, _15_30 (cm)	clay_0_5
Cumuls météo	_cumul, _sum	gdd_cumul
Dates en jour-an	_doy (Day of Year, 1-365)	harvest_doy

2.2 Types de données et formats

Type Pandas	Usage dans le projet	Exemple
str / object	Identifiants, codes, libellés	parcelle_uid = "2020_4771311"
int / int64	Année, nombre entier, code	year = 2020
float / float64	Mesures continues (températures, indices)	NDVI = 0.847
datetime64	Dates ou timestamps	scene_date = "2020-05-15"
bool	Flags binaires	is_valid = True
geometry	Polygones / points (GeoPandas)	point Shapely WKT

2.3 Système de coordonnées géographiques

Système de référence unique : toutes les coordonnées géographiques du projet sont exprimées en **WGS84** (EPSG:4326), avec longitude (X) et latitude (Y) en degrés décimaux. Cette convention est compatible avec Google Earth Engine, les services web de cartographie, et l'écosystème Sentinel/Copernicus.

Donnée	Système original	Système final
RPG parcelles	Lambert 93 (EPSG:2154)	WGS84 (EPSG:4326)
Sentinel-2	UTM 31N (EPSG:32631)	Réutilisé à 20m, agrégé par parcelle
Sentinel-1	UTM 31N	Réutilisé à 30m, agrégé par parcelle
SoilGrids	WGS84 (EPSG:4326), 250m	Directement utilisé
NASA POWER	WGS84, grille 0.5°	Directement utilisé (6 points préfectures)

2.4 Conventions temporelles

Concept	Convention	Exemple
Année de récolte	Année du juillet de récolte	"saison 2020" = oct 2019 → juil 2020
Date courante	ISO 8601 : YYYY-MM-DD	2020-07-03

Day of Year (DOY)	Entier 1-365 (ou 366 bissextile)	1 juillet 2020 → DOY 183
Fuseau horaire	UTC pour toutes les acquisitions	Pas de tz locale dans les données
Fenêtre temporelle	window_start (début inclusif)	composite 15j à partir du 1er mai

2.5 Conventions d'unités

Grandeur physique	Unité standard du projet	Notes
Température	°C (Celsius)	Pas de Kelvin/Fahrenheit
Précipitations	mm/jour	Équivalents litres/m²
Rayonnement solaire	MJ/m²/jour	(NB : NASA POWER fournit en MJ/m²/jour)
Vent	m/s	Pas de km/h ni nœuds
Humidité relative	% (0-100)	Pas de fraction (0-1)
Indices végétation	Sans unité, [-1, +1]	NDVI, EVI, NDWI
Backscatter SAR	dB (décibels)	Échelle logarithmique
Surface parcelles	hectares (ha)	1 ha = 10 000 m²
Profondeur sol	cm	Tranches 0-5, 5-15, 15-30
Capacité rétention eau	mm	Équivalent hauteur d'eau
pH du sol	Sans unité, 0-14	Échelle logarithmique

2.6 Valeurs spéciales

Valeur	Signification	Convention de traitement
NaN (float)	Donnée manquante	Standard pandas, à imputer ou filtrer
None	Absence d'objet (rare dans nos données)	Converti en NaN dans CSV
-9999	(Rare) Sentinelle GEE pour nodata	À remplacer par NaN après lecture
" " (chaîne vide)	Texte manquant	Converti en NaN

2.7 Locale et séparateurs CSV

Élément	Convention
Séparateur de colonnes	, (virgule, standard CSV)
Séparateur décimal	. (point, anglo-saxon)
Encodage	UTF-8
En-têtes	Première ligne du fichier
Caractères d'échappement	" autour des chaînes contenant des virgules

3. Schéma de fusion des 6 sources

Les 6 sources ont des **granularités différentes**. La table suivante résume comment chacune sera fusionnée pour construire le master dataset.

3.1 Granularités natives

Source	Granularité spatiale	Granularité temporelle	Cardinalité
Céré'Obs	Région CVL (1)	Par année (5)	5 lignes valides
RPG	Par parcelle (1500)	Statique	1 500 lignes
NASA POWER	Par chef-lieu (6 points)	Quotidien (1 766 jours)	10 596 lignes
SoilGrids	Par parcelle (1500)	Statique	1 500 lignes × 39 features
Sentinel-2 (15j)	Par parcelle	15 jours (118 fenêtres)	~177 000 lignes
Sentinel-1 SAR	Par parcelle	Scène par scène (~5j)	~3 000 000 lignes (5 fichiers)

3.2 Stratégie de fusion

Principe : on agrège **toutes les sources temporelles** en features par (**parcelle × année**), ce qui produit un master dataset "long-format" avec 1500 lignes (1 ligne par observation) et ~200 colonnes.

Source	Méthode d'agrégation	Features produites
Céré'Obs	Jointure directe par <code>year</code>	1 colonne cible <code>harvest_doy</code>
RPG	Jointure directe par <code>parcelle_uid</code>	Métadonnées : surface, département, commune
NASA POWER	Cumuls et statistiques sur fenêtres (Oct → Juil)	~40 colonnes (GDD, ET0, bilan hydrique cumul)
SoilGrids	Jointure directe par <code>parcelle_uid</code>	39 colonnes (13 propriétés × 3 profondeurs)
Sentinel-2	Features dérivées : <code>peak_doy</code> , <code>senescence_doy</code> , intégrale	~30-50 colonnes
Sentinel-1 SAR	Features dérivées : <code>vv_min_doy</code> , <code>vh_amplitude</code> , <code>recovery</code>	~30-50 colonnes

3.3 Clés de jointure

Source	Clé(s)	Type
Céré'Obs	<code>year</code>	int (2020-2024)
RPG / SoilGrids / S2 / S1	<code>parcelle_uid</code>	str (format "YYYY_IDPARCEL")
NASA POWER	<code>departement</code> + <code>date</code>	str + datetime

Attention — `parcelle_uid` contient l'année : contrairement à un identifiant universel, `parcelle_uid` dépend de l'année. La parcelle physique identifiée par "2020_4771311" n'est PAS la même que "2021_4771311". L'identifiant IGN sous-jacent peut être réutilisé d'une année à l'autre par l'IGN, mais nous avons fait le choix de re-tirer 300 parcelles aléatoires chaque année. Donc :

- **Pas de continuité temporelle** par parcelle
- Chaque (`parcelle_uid`, `year`) est une observation indépendante
- Le sol et la météo sont rattachés à la parcelle physique de l'année

3.4 Méthode de jointure recommandée (Pandas)

```
# Pseudocode de fusion finale
import pandas as pd

# 1. Charger les sources raw
cereobs = pd.read_csv('cereobs.csv')           # 5 lignes
rpg = pd.read_csv('parcelles_rpg.csv')         # 1500 lignes
soil = pd.read_csv('soilgrids.csv')            # 1500 lignes
meteo = pd.read_csv('nasa_power.csv')          # 10596 lignes
s2 = pd.read_csv('s2_15days.csv')             # 177000 lignes
s1 = pd.concat([pd.read_csv(f's1_raw_{y}.csv') for y in range(2020,2025)])

# 2. Agréger les sources temporelles en (parcelle x année)
s2_features = compute_s2_features(s2)         # 1500 lignes x ~30 cols
s1_features = compute_s1_features(s1)         # 1500 lignes x ~30 cols
meteo_features = compute_meteo_features(rpg, meteo) # 1500 lignes x ~40 cols

# 3. Fusion finale
master = rpg.merge(soil, on='parcelle_uid')
master = master.merge(s2_features, on='parcelle_uid')
master = master.merge(s1_features, on='parcelle_uid')
master = master.merge(meteo_features, on='parcelle_uid')
master = master.merge(cereobs, on='year')      # Jointure par année

# Result: 1500 lignes x ~200 colonnes
master.to_csv('master_dataset.csv', index=False)
```

PARTIE II — Description par source

5. Source 1 — Céré'Obs (cible)

Phénologie céréalière française · Variable cible du projet

FOURNISSEUR FranceAgriMer + Arvalis	TYPE Phénologie observée	GRANULARITÉ Régionale, annuelle	PÉRIODE Depuis 2015
--	-----------------------------	------------------------------------	------------------------

5.1 Présentation

Céré'Obs est un service public français qui suit chaque année les stades phénologiques des céréales à paille (blé tendre, blé dur, orge, etc.) sur l'ensemble du territoire. Les observations sont réalisées par un réseau de techniciens d'Arvalis (Institut du végétal) sur des parcelles témoins, et publiées en hebdomadaire et en fin de campagne.

Pour notre projet, on utilise la **date de récolte 50%** à l'échelle régionale (CVL) pour chaque année de 2020 à 2024.

Variable cible (target) du projet : la date à laquelle **50% des parcelles de blé tendre de la région CVL** ont atteint le stade BBCH 92 (grain mûr, récoltable). C'est l'unique target Y que nos modèles ML chercheront à prédire à partir des features X.

5.2 Schéma du fichier source

Fichier original : SCR-GRC-CERE0BS_CP_depuis_2015-A26.xlsx

Le fichier Excel contient les colonnes principales suivantes :

Colonne (originale)	Type	Description
CAMPAGNE	str	Année (ex: "2020"). C'est l'année de récolte.
CULTURE	str	Type de culture (filtrer "BTH" = Blé Tendre d'Hiver)
REGION	str	Nom de région (filtrer "Centre-Val de Loire")
SEMAINE	str	Numéro de semaine ISO (ex: "2020-S27")
DATE_DEBUT_SEMAINE	date	Premier jour de la semaine d'observation
SURFACE_RECOLTEE_PCT	float	% de surface régionale récoltée à cette date (0-100)

5.3 Méthode d'extraction de la cible

La date de récolte 50% n'est pas explicitement donnée. On l'extrait par **interpolation linéaire** sur la série hebdomadaire :

- Filtrer le fichier sur (CULTURE = "BTH") et (REGION = "Centre-Val de Loire")
- Pour chaque année, identifier les deux semaines encadrant 50% de récolte
- Interpoler linéairement la date où SURFACE_RECOLTEE_PCT = 50
- Convertir cette date en DOY (jour de l'année)

5.4 Résultat — valeurs finales

Année	DOY récolte 50%	Date calendaire	Particularité
2020	185	3 juillet 2020	Année moyenne
2021	199	18 juillet 2021	+14j (printemps frais)
2022	183	2 juillet 2022	-2j (canicule mai)
2023	184	3 juillet 2023	Moyenne
2024	195	13 juillet 2024	+10j (printemps humide)

5.5 Variables produites pour le master dataset

Colonne finale	Type	Unité	Description	Tag
year	int	—	Année de récolte (2020-2024)	CLÉ
harvest_doy	int	jour de l'année	DOY de récolte 50% régionale	TARGET
harvest_date	date	YYYY-MM-DD	Date calendaire de récolte 50%	TARGET

Limite importante : la cible est **régionale**, pas **parcellaire**. Toutes les parcelles d'une même année ont la même valeur de `harvest_doy` . Notre modèle prédit donc la date régionale moyenne, en exploitant la variabilité des features d'entrée (qui sont, elles, parcellaires). C'est une simplification : dans un projet idéal, on aurait des vraies dates de récolte par parcelle, mais ces données ne sont pas publiques.

6. Source 2 — RPG (Registre Parcellaire Graphique)

Cadastre agricole national · Géolocalisation des 1500 parcelles

FOURNISSEUR

IGN + Ministère Agriculture

TYPE

Vecteur géospatial (polygones)

FORMAT

Shapefile / GeoPackage

PÉRIODE

Annuel, depuis 2007

6.1 Présentation

Le **Registre Parcellaire Graphique (RPG)** est la base nationale française qui répertorie toutes les parcelles agricoles déclarées par les exploitants dans le cadre de la PAC (Politique Agricole Commune européenne). Chaque parcelle y est représentée par :

- Un **polygone géographique** (forme exacte du champ)
- Le **code culture** (espèce cultivée cette année-là, ex: "BTH" pour blé tendre)
- Un **identifiant unique** (par année)
- Des métadonnées (surface, code commune INSEE...)

Pour notre projet, le RPG sert à **identifier et géolocaliser** les 1500 parcelles de blé.

6.2 Stratégie d'échantillonnage

Critère	Valeur
Région	Centre-Val de Loire (6 départements)
Culture filtre	BTH (Blé Tendre d'Hiver)
Surface minimale	1 hectare (pour éviter petites parcelles bruitées)
Échantillonnage	Aléatoire par année (random_state=42)
Nombre par année	300 parcelles
Total	1 500 parcelles (300 × 5 ans)

6.3 Schéma du fichier final

Fichier : `parcelles_ble_cvl_sample.csv` et `parcelles_ble_cvl_sample.geojson`

Colonne	Type	Unité	Description	Tag
<code>parcelle_uid</code>	str	—	Identifiant unique "YYYY_IDPARCEL" (ex: "2020_4771311")	CLÉ
<code>year</code>	int	—	Année de la campagne agricole (2020-2024)	CLÉ
<code>id_parcel</code>	str	—	Identifiant IGN original de la parcelle	META
<code>code_cultu</code>	str	—	Code culture (toujours "BTH" dans notre échantillon)	META
<code>surf_parc</code>	float	hectares	Surface de la parcelle (≥1 ha par construction)	FEATURE
<code>departement</code>	str	—	Code département INSEE (18, 28, 36, 37, 41, 45)	META
<code>commune</code>	str	—	Code commune INSEE	META
<code>latitude</code>	float	degrés WGS84	Latitude du centroïde de la parcelle	META
<code>longitude</code>	float	degrés WGS84	Longitude du centroïde de la parcelle	META
<code>geometry</code>	Polygon WKT	—	Polygone WGS84 (présent uniquement dans .geojson)	META

6.4 Statistiques descriptives

Métrique	Valeur
----------	--------

Nombre total de parcelles	1 500
Surface moyenne	7.9 ha
Surface médiane	5.2 ha
Surface min / max	1.0 ha / 89.4 ha
Étendue géographique (lat)	46.4° N → 48.9° N
Étendue géographique (lon)	0.1° E → 3.1° E

6.5 Validation de l'indépendance annuelle

Vérification effectuée : nous avons vérifié que la **rotation culturale** en CVL est suffisamment forte pour considérer les parcelles indépendantes d'une année à l'autre. Sur 5 années d'observation, seulement **17,1 % des parcelles** portent du blé deux années consécutives. Cela valide notre stratégie d'échantillonnage indépendant chaque année.

7. Source 3 — NASA POWER (météo journalière)

Réanalyses météorologiques globales · Variables climatiques

FOURNISSEUR
NASA Langley

TYPE
Réanalyses + observations

GRANULARITÉ
Grille 0.5° × 0.5°

PÉRIODE
Depuis 1981, quotidien

7.1 Présentation

NASA POWER (Prediction Of Worldwide Energy Resources) est un service de la NASA qui fournit des données météorologiques quotidiennes globales, dérivées de réanalyses atmosphériques et de mesures satellitaires. C'est gratuit, accessible via API, et couvre toute la planète.

Pour notre projet, on extrait les données pour **6 points** (un par département CVL, correspondant au chef-lieu), sur la période **2019-10-01** → **2024-07-31**.

7.2 Points d'extraction

Département	Chef-lieu	Latitude	Longitude
28 (Eure-et-Loir)	Chartres	48.45°	1.49°
45 (Loiret)	Orléans	47.90°	1.91°
41 (Loir-et-Cher)	Blois	47.59°	1.33°
37 (Indre-et-Loire)	Tours	47.39°	0.69°
18 (Cher)	Bourges	47.08°	2.40°
36 (Indre)	Châteauroux	46.81°	1.69°

7.3 Variables brutes téléchargées (8)

Code NASA	Description	Unité
T2M	Température à 2m (moyenne journalière)	°C
T2M_MIN	Température à 2m (minimum journalier)	°C
T2M_MAX	Température à 2m (maximum journalier)	°C
PRECTOTCORR	Précipitations totales corrigées	mm/jour
RH2M	Humidité relative à 2m	%
WS2M	Vitesse du vent à 2m	m/s
ALLSKY_SFC_SW_DWN	Rayonnement solaire descendant tous-temps	MJ/m²/jour
PS	Pression de surface	kPa

7.4 Variables dérivées (22)

À partir des 8 variables brutes, on calcule **22 indicateurs agronomiques** :

Degrés-jours (GDD)

Colonne	Calcul	Unité
gdd_base0	$(T_{\text{max}} + T_{\text{min}})/2 - 0$ (si > 0)	°C·j
gdd_base5	$(T_{\text{max}} + T_{\text{min}})/2 - 5$ (si > 0)	°C·j
gdd_base0_cumul	Somme cumulée depuis le 1er octobre	°C·j

gdd_base5_cumul	Somme cumulée depuis le 1er octobre	°C.j
-----------------	-------------------------------------	------

Évapotranspiration et bilan hydrique

Colonne	Calcul	Unité
et0	Formule Penman-Monteith FAO-56	mm/jour
et0_cumul	ET0 cumulé depuis 1er octobre	mm
bilan_hydrique	PRECOTCORR – ET0	mm/jour
bilan_hydrique_cumul	Bilan cumulé depuis 1er octobre	mm

Indicateurs de stress

Colonne	Calcul	Unité
amplitude_therm	T_max – T_min	°C
jours_chauds	1 si T_max > 30°C sinon 0	bool
jours_chauds_cumul	Nombre cumulé de jours chauds	nombre
pluie_30j	Pluie cumulée 30 derniers jours	mm
rayonnement_cumul	Rayonnement cumulé depuis 1er oct	MJ/m²

Note méthodologique — Correction de bug ET0 : dans la première version du pipeline, nous avons appliqué par erreur une conversion $\times 3.6$ au rayonnement ALLSKY_SFC_SW_DWN avant le calcul de l'ET0, supposant qu'il fournissait des Wh/m². En réalité, NASA POWER fournit le rayonnement déjà en **MJ/m²/jour**, donc aucune conversion n'est nécessaire. Cette erreur, qui inflait artificiellement l'ET0, a été corrigée. La version actuelle utilise les valeurs natives sans transformation supplémentaire.

7.5 Schéma final du fichier

Fichier : meteo_nasapower_cv1_2020_2024.csv · 10 596 lignes × 30 colonnes

Colonne	Type	Description	Tag
departement	str	Code département (18, 28, 36, 37, 41, 45)	CLÉ
date	date	Date d'observation	CLÉ
(les 8 brutes)	float	T2M, T2M_MIN, ..., PS	FEATURE
(les 22 dérivées)	float	GDD, ET0, bilan hydrique, etc.	DÉRIVÉ

8. Source 4 — SoilGrids (sol)

Propriétés physico-chimiques du sol · 13 variables × 3 profondeurs

FOURNISSEUR

ISRIC World Soil Info

TYPE

Raster prédictif (ML géostat)

RÉSOLUTION

250 m

COUVERTURE

Mondiale

8.1 Présentation

SoilGrids est une base mondiale de cartes prédictives des propriétés du sol, produite par l'ISRIC (organisation néerlandaise dédiée à l'information sur les sols). Les cartes sont générées par machine learning à partir de centaines de milliers de profils pédologiques de référence.

Pour notre projet, on extrait **13 propriétés à 3 profondeurs** (0-5 cm, 5-15 cm, 15-30 cm), au point central de chaque parcelle.

8.2 Les 13 propriétés extraites

Propriété	Code	Unité	Plage typique (blé CVL)
Bulk Density	bdod	kg/dm ³	1.3 – 1.6
Cation Exchange Capacity	cec	cmol(+)/kg	8 – 25
Coarse Fragments (cailloux)	cfvo	cm ³ /dm ³	0 – 150
Clay (argile)	clay	g/kg (‰)	100 – 350
Nitrogen (azote total)	nitrogen	cg/kg	50 – 200
pH (eau)	phh2o	pH × 10	55 – 75 (= pH 5.5-7.5)
Sand (sable)	sand	g/kg	200 – 600
Silt (limon)	silt	g/kg	250 – 600
Soil Organic Carbon	soc	dg/kg	50 – 250
SOC Density	ocd	hg/m ³	30 – 150
SOC Stock	ocs	t/ha	10 – 60
Water Capacity (10 kPa)	wv0010	cm ³ /dm ³	250 – 400
Water Capacity (1500 kPa)	wv1500	cm ³ /dm ³	100 – 250

Attention aux unités SoilGrids : les valeurs sont stockées en **entiers** avec un facteur d'échelle pour économiser l'espace. Par exemple, le pH est multiplié par 10 (donc pH 6.5 = valeur 65). Vérifier les facteurs d'échelle de chaque variable dans la documentation officielle SoilGrids.

8.3 Les 3 profondeurs

Chaque propriété est mesurée à 3 profondeurs représentant la **zone racinaire principale** du blé :

Profondeur	Suffixe	Intérêt
0 – 5 cm	_0_5	Surface du sol — premier contact avec semis
5 – 15 cm	_5_15	Zone d'enracinement principale
15 – 30 cm	_15_30	Zone d'extension du système racinaire

8.4 Schéma final

Fichier : `soilgrids_features_cv1_1500.csv` · 1500 lignes × 41 colonnes

Colonne	Type	Description	Tag
---------	------	-------------	-----

parcelle_uid	str	Identifiant parcelle	CLÉ
year	int	Année	CLÉ
clay_0_5	float	Argile (g/kg) à 0-5 cm	FEATURE
clay_5_15	float	Argile à 5-15 cm	FEATURE
clay_15_30	float	Argile à 15-30 cm	FEATURE

... (idem pour les 12 autres propriétés × 3 profondeurs = 39 colonnes au total)

8.5 Méthodologie d'extraction (WCS)

Optimisation méthodologique : nous avons initialement testé l'API REST point-par-point de SoilGrids, qui aurait pris ~5 heures pour les 1500 parcelles. En passant à une **extraction par raster WCS** (Web Coverage Service) — téléchargement des 39 rasters complets puis échantillonnage local — le temps a chuté à **3,3 minutes**, soit un gain de **91× plus rapide**.

8.6 Gestion des valeurs manquantes

Sur 1500 parcelles, 2 (0.13 %) avaient des valeurs **NoData** pour certaines propriétés, dues à des artefacts du raster SoilGrids près des frontières administratives. Nous avons appliqué une **imputation par plus proche voisin** (distance 0.22 km = 1 pixel SoilGrids), ce qui est agronomiquement justifié (les propriétés du sol varient peu à cette distance).

9. Source 5 — Sentinel-2 (indices végétation)

Optique multispectral · NDVI, EVI, NDWI à 3 granularités

FOURNISSEUR
ESA (Copernicus)

MISSION
Sentinel-2A / 2B

RÉSOLUTION
10-20 m

REVISITE
~5 jours (S2A+S2B)

9.1 Présentation

Sentinel-2 est une constellation de deux satellites optiques (S2A lancé en 2015, S2B en 2017) fournissant des images multispectrales de la Terre à haute résolution. L'instrument MSI (Multi-Spectral Instrument) à bord capture 13 bandes spectrales du visible au SWIR.

Pour notre projet, on utilise la collection **COPERNICUS/S2_SR_HARMONIZED** via Google Earth Engine, qui fournit des produits de réflectance de surface (Level-2A), corrigés atmosphériquement et harmonisés sur 2017-aujourd'hui.

9.2 Bandes spectrales utilisées

Bande	Nom	Longueur d'onde	Résolution	Usage
B2	Bleu	490 nm	10 m	EVI (correction atmosphère)
B4	Rouge	665 nm	10 m	NDVI, EVI
B8	NIR	842 nm	10 m	NDVI, EVI, NDWI
B11	SWIR	1610 nm	20 m	NDWI

9.3 Indices calculés

Indice	Formule	Plage	Capture
NDVI	$(B8 - B4) / (B8 + B4)$	[-1, 1]	Verdeur, vigueur photosynthétique
EVI	$2.5 \times (B8 - B4) / (B8 + 6 \times B4 - 7.5 \times B2 + 1)$	[-1, 1]*	Vigueur (correction sol/atmosphère)
NDWI	$(B8 - B11) / (B8 + B11)$	[-1, 1]	Hydratation foliaire

* L'EVI peut produire des valeurs aberrantes (jusqu'à ±67) en cas de pixels sombres ou divergences numériques. **Filtrage recommandé : $|EVI| < 1.5$** avant toute modélisation (159 outliers sur 131 287 valeurs valides, soit 0.12%).

9.4 Pipeline d'extraction

- Filtrage collection** : COPERNICUS/S2_SR_HARMONIZED, dates 2019-10-01 → 2024-07-31, intersection avec parcelles, CLOUDY_PIXEL_PERCENTAGE < 60%
- Masquage nuages** : Scene Classification Layer (SCL) — exclusion des classes 3 (ombre nuage), 7-9 (probabilités nuages), 10 (cirrus), 11 (neige)
- Calcul des 3 indices** par scène
- Agrégation par parcelle** : reduceRegions avec moyenne spatiale à 20 m
- Production de 3 granularités** :
 - Composites 15 jours (118 fenêtres × 5 statistiques) → ML classique
 - Composites 7 jours (253 fenêtres × 5 statistiques) → modèles séquentiels
 - Raw par scène, par année (5 fichiers) → flexibilité maximale

9.5 Schéma des composites (15j et 7j)

Fichiers : `sentinel2_composites_15days_cvl.csv` (177k lignes) · `sentinel2_composites_7days_cvl.csv` (~380k lignes)

Colonne	Type	Unité	Description	Tag
---------	------	-------	-------------	-----

parcelle_uid	str	—	Identifiant parcelle	CLÉ
year	int	—	Année (2020-2024)	CLÉ
window_start	date	YYYY-MM-DD	Début de la fenêtre composite	META
window_days	int	jours	Longueur fenêtre (7 ou 15)	META
n_images	int	—	Nombre de scènes valides dans la fenêtre	META
NDVI_median	float	[-1, 1]	NDVI médian sur la fenêtre	FEATURE
NDVI_mean	float	[-1, 1]	NDVI moyen	FEATURE
NDVI_max	float	[-1, 1]	NDVI maximum (pic local)	FEATURE
NDVI_min	float	[-1, 1]	NDVI minimum	FEATURE
NDVI_stdDev	float	≥ 0	Écart-type NDVI (variabilité)	FEATURE
EVI_* (×5)	float	[-1, 1]	Mêmes 5 stats pour EVI	FEATURE
NDWI_* (×5)	float	[-1, 1]	Mêmes 5 stats pour NDWI	FEATURE

Total : 19 colonnes (4 identifiants/méta + 15 features = 5 stats × 3 indices)

9.6 Schéma des fichiers raw (5 fichiers annuels)

Fichiers : sentinel2_raw_2020.csv ... sentinel2_raw_2024.csv

Colonne	Type	Description	Tag
parcelle_uid	str	Identifiant parcelle	CLÉ
year	int	Année	CLÉ
scene_date	date	Date d'acquisition de la scène S2	META
NDVI	float	NDVI moyen de la parcelle pour cette scène	FEATURE
EVI	float	EVI moyen	FEATURE
NDWI	float	NDWI moyen	FEATURE

Structure NaN des fichiers raw : ~92% des lignes contiennent des NaN. Ce n'est **pas** une perte de données : Google Earth Engine produit une ligne par (parcelle × scene_date), mais chaque scène S2 ne couvre qu'une partie du territoire. Les parcelles hors de l'empreinte de la scène reçoivent NaN. Pour obtenir les vraies mesures :
`df.dropna(subset=['NDVI'])` → ~80 000 mesures valides par année, médiane ~42 scènes par parcelle.

9.7 Qualité des données

Indicateur	Valeur
Composites 15j : taux de NaN	25.8 % (concentré en hiver)
Période critique (mai-juillet) : NaN	5-22 % (très bon)
Outliers EVI	0.12 % (à filtrer EVI < 1.5)
Corrélation NDVI ↔ NDWI	r = 0.93 (quasi-redondance)
Pic NDVI typique du blé	0.80 - 0.90 (avril-mai)

10. Source 6 — Sentinel-1 SAR (radar)

Radar à synthèse d'ouverture · Backscatter VV/VH tout-temps

FOURNISSEUR
ESA (Copernicus)

MISSION
Sentinel-1A / 1B

RÉSOLUTION
10 m (mode IW)

REVISITE
~6 jours (S1A+S1B)

10.1 Présentation

Sentinel-1 est une constellation de deux satellites radar SAR (Synthetic Aperture Radar) en bande C, opérant à 5.4 GHz. Contrairement à Sentinel-2 (optique passif), Sentinel-1 émet ses propres ondes radar et mesure leur écho — il fonctionne **en tout temps**, à travers les nuages, de jour comme de nuit.

Pour notre projet, on utilise la collection **COPERNICUS/S1_GRD** (Ground Range Detected) via Google Earth Engine, qui fournit des produits déjà calibrés en dB.

10.2 Configuration d'acquisition

Paramètre	Valeur retenue	Justification
Mode d'instrument	IW (Interferometric Wide)	Standard pour observation terrestre, 250 km de fauchée
Polarisations	VV + VH	Les deux polarisations transmises sur terre
Orbite	DESCENDING uniquement	Géométrie cohérente (angle d'incidence stable)
Résolution	10 m	Produit haute résolution
Unité	dB (décibels)	Calibration radiométrique GEE native

10.3 Pré-traitement appliqué

- Calibration** : automatique par GEE lors de l'ingestion (σ^0 en dB)
- Filtre speckle** : `focal_median 50 m` par scène, réduit le bruit granulaire
- Calcul du ratio** : $VV/VH = VV - VH$ (en dB, soustraction = ratio en linéaire)
- Agrégation parcellaire** : moyenne spatiale à 30 m (sur-échantillonnage)

10.4 Variables produites

Variable	Type	Plage typique (blé)	Signification
VV	float (dB)	[-15, -5]	Backscatter en co-polarisation, surfaces et structures verticales
VH	float (dB)	[-22, -12]	Backscatter en cross-polarisation, diffusion volumique (biomasse)
VV_VH_ratio	float (dB)	[4, 12]	Ratio = indicateur de densité de canopée

10.5 Schéma des fichiers

Fichiers (5) : `sentinel1_sar_raw_2020.csv` ... `sentinel1_sar_raw_2024.csv`

Colonne	Type	Description	Tag
<code>parcelle_uid</code>	str	Identifiant parcelle	CLÉ
<code>year</code>	int	Année (2020-2024)	CLÉ
<code>scene_date</code>	date	Date d'acquisition de la scène S1	META
<code>VV</code>	float (dB)	σ^0 en polarisation VV	FEATURE
<code>VH</code>	float (dB)	σ^0 en polarisation VH	FEATURE

VV_VH_ratio	float (dB)	VV – VH	FEATURE
-------------	------------	---------	---------

10.6 Statistiques des données (saison 2020 validée)

Indicateur	Valeur	Verdict
Lignes brutes	601 500	1500 parcelles × 401 scene_date
Lignes valides (non-NaN)	119 491 (19.9 %)	Structurel (footprint scène)
Scènes valides / parcelle	médiane 100 (max 124)	2.4× plus dense que S2
VV médian (toute saison)	-10.7 dB	✓ Plage attendue blé
VH médian	-18.5 dB	✓ Plage attendue (VH < VV)
Ratio VV/VH médian	7.7 dB	✓ Plage attendue

10.7 Signature phénologique SAR du blé

L'évolution du VV au cours de la saison reflète directement la structure de la canopée :

Période	VV médian (dB)	Stade	Interprétation physique
Oct-Nov	-9.2 à -8.9	Semis / tallage	Sol rugueux + petite végétation → forte rétrodiffusion
Déc-Fév	-9.0 à -9.6	Croissance lente	Couvert partiel, peu de biomasse
Mars	-10.7	Montaison	Canopée se développe, atténuation du signal sol
Avr-Mai	-13.5	Épiaison/floraison	Canopée dense, atténuation max → VV minimum
Juin	-12.3	Maturation	Sénescence commence, atténuation décroît
Juillet	variable	Récolte	Forte variabilité : passage de moissonneuse

Marqueur de récolte SAR : la remontée brutale du ratio VV/VH (de ~6 à ~8 dB) après son minimum d'avril-mai est physiquement liée à la disparition de la canopée par récolte. C'est l'un des signaux les plus prometteurs pour la prédiction ML.

10.8 Complémentarité S2 ↔ S1

La grande force de Sentinel-1 est sa couverture **uniforme toute l'année** :

Mois	S2 (scènes/parcelle)	S1 (scènes/parcelle)	Total S1+S2
Décembre	2.6	8.0	10.6
Janvier	5.2	8.0	13.2
Février	2.4	8.0	10.4
Avril	8.0	8.0	16.0
Juillet	10.8	8.0	18.8

La densité combinée S1+S2 atteint **~18 scènes/parcelle/mois en moyenne**, permettant des architectures multimodales séquentielles avancées.

PARTIE III — Schéma maître et features dérivées

11. Schéma cible du master dataset

11.1 Vue d'ensemble

Le **master dataset** est le fichier final qui sera utilisé pour entraîner les modèles ML. Il agrège toutes les 6 sources en une structure tabulaire unifiée.

Cible structure : 1 500 lignes × ~200 colonnes
1 ligne = 1 observation (1 parcelle × 1 année)
1 colonne = 1 feature (ou la cible)
Format : CSV ou Parquet

11.2 Catégories de colonnes

Catégorie	Source	Nb colonnes	Préfixe
Identifiants	—	2	—
Métadonnées parcelle	RPG	~5	—
Cible	Céré'Obs	1	harvest_
Features sol	SoilGrids	39	soil_
Features météo dérivées	NASA POWER	~40	meteo_
Features Sentinel-2 dérivées	S2	~30	s2_
Features Sentinel-1 dérivées	S1	~30	s1_
Flags qualité	—	~5	flag_
TOTAL	—	~152	—

11.3 Aperçu du schéma maître

Section	Colonnes (exemples)	Tag
Identifiants	parcelle_uid, year	CLÉ
Métadonnées	departement, surf_parc, latitude, longitude	META
Cible	harvest_doy	TARGET
Sol (statique)	soil_clay_0_5, soil_clay_5_15, ..., soil_phh2o_15_30	FEATURE
Météo	meteo_gdd_cumul_apr30, meteo_et0_cumul_jun15, meteo_rainfall_amjJ	DÉRIVÉ
Sentinel-2	s2_peak_ndvi, s2_peak_doy, s2_senescence_doy, s2_ndvi_integral_amj	DÉRIVÉ
Sentinel-1	s1_vv_min, s1_vv_min_doy, s1_ratio_recovery_doy	DÉRIVÉ
Qualité	flag_s2_coverage_ok, flag_s1_coverage_ok, flag_outlier_evi	META

12. Features dérivées prévues

12.1 Principe

Les features dérivées (encore appelées "**engineered features**") sont des indicateurs synthétiques calculés à partir des séries temporelles brutes. Elles concentrent l'information phénologique dans une seule valeur par parcelle-année, accessible aux modèles ML classiques.

Rappel : les modèles à base d'arbres (RF, XGBoost) ne savent pas traiter directement des séries temporelles longues. Pour ces modèles, on doit transformer chaque série en quelques scalaires (features dérivées). Les modèles séquentiels (LSTM, Transformer) peuvent eux travailler directement sur les séries brutes.

12.2 Features dérivées de Sentinel-2 (~25)

Feature	Calcul	Signification
s2_peak_ndvi	max(NDVI) sur la saison	Vigueur maximale atteinte
s2_peak_doy	DOY du max NDVI	Date de canopée maximale (proxy épiaison)
s2_senescence_doy	1er DOY après pic où NDVI < 0.4	Date de sénescence avancée
s2_senescence_slope	$(NDVI_{pic} - NDVI_{sen}) / (doy_{sen} - doy_{pic})$	Vitesse de chute = vitesse de maturation
s2_ndvi_integral_amj	Intégrale (aire sous courbe) avr-juin	Proxy biomasse cumulée période critique
s2_ndvi_april_mean	Moyenne NDVI sur avril	Vigueur précoce
s2_ndvi_may_mean	Moyenne NDVI sur mai	Vigueur au pic
s2_ndvi_june_mean	Moyenne NDVI sur juin	Vigueur en début maturation
s2_evi_peak	max(EVI) sur la saison	EVI alternatif au NDVI
s2_ndwi_peak	max(NDWI) sur la saison	Pic d'hydratation foliaire
s2_ndwi_drop_doy	DOY où NDWI chute sous 0	Détection précoce du stress hydrique
s2_n_valid_scenes_amj	Nombre de scènes valides avr-juin	Indicateur de couverture utile

12.3 Features dérivées de Sentinel-1 (~25)

Feature	Calcul	Signification
s1_vv_min	min(VV) sur la saison	Valeur min VV (canopée max)
s1_vv_min_doy	DOY du min VV	Date de canopée max selon SAR
s1_vv_amplitude	$VV_{max} - VV_{min}$ sur la saison	Amplitude de variation
s1_vv_post_min_slope	$(VV_{jul} - VV_{min}) / nb_jours$	Vitesse de remontée = sénescence
s1_vh_integral_amj	Intégrale VH sur avr-juin	Proxy biomasse via diffusion volumique
s1_ratio_min	min(VV/VH) sur la saison	Densité canopée max
s1_ratio_min_doy	DOY du min ratio	Date canopée végétative max
s1_ratio_recovery_doy	DOY où ratio remonte de +1.5 dB après min	★ Marqueur direct de récolte
s1_ratio_amplitude	$ratio_{max} - ratio_{min}$ sur la saison	Amplitude saisonnière
s1_vv_mean_amj	VV moyen sur avr-juin	Vigueur structurelle moyenne

12.4 Features dérivées météo (~40)

Feature	Calcul	Importance
meteo_gdd_cumul_apr30	GDD base 0°C cumulé du 1er oct au 30 avr	Indicateur précoce de maturation
meteo_gdd_cumul_may31	GDD au 31 mai	Cumul à l'épiaison
meteo_gdd_cumul_jun30	GDD au 30 juin	Cumul juste avant récolte (proxy direct)
meteo_rainfall_amj	Cumul pluies avril-mai-juin	Disponibilité hydrique critique
meteo_et0_cumul_amj	Cumul ET0 avril-juin	Demande évaporative cumulée
meteo_bilan_hydrique_amj	Cumul (pluies – ET0) avril-juin	Bilan hydrique période critique
meteo_jours_chauds_mj	Nombre jours T_max > 30°C en mai-juin	Risque d'échaudage canicule
meteo_amplitude_thermique_mean_amj	Amplitude thermique moyenne avr-juin	Stress thermique journalier
meteo_rayonnement_cumul_amj	Rayonnement cumulé avril-juin	Énergie pour photosynthèse

12.5 Note importante sur les features dérivées

Construction des features dérivées : ces features ne sont **pas encore présentes** dans les fichiers raw publiés sur Kaggle. Elles seront calculées au moment de la construction du master dataset (phase suivante du projet). Cette section sert donc de **spécification cible** plutôt que de description d'un fichier existant.

13. Variables de qualité et flags

Pour assurer la traçabilité et faciliter le débogage du modèle, on prévoit d'ajouter des **flags de qualité** au master dataset :

Flag	Type	Signification
flag_s2_coverage_ok	bool	True si $\geq 50\%$ des fenêtres composites 15j sont valides
flag_s1_coverage_ok	bool	True si ≥ 80 scènes valides sur la saison
flag_soil_imputed	bool	True si valeurs sol imputées par voisin (2 parcelles)
flag_outlier_evi	bool	True si des outliers EVI détectés au cours de la saison
flag_extreme_year	bool	True pour les années climatiques atypiques (2021, 2022)

PARTIE IV — Annexes

14. Codes erreurs et valeurs spéciales

Valeur	Source possible	Action de pré-traitement
NaN	Tous fichiers (donnée manquante)	dropna() ou imputation selon contexte
EVI > 1.5	Sentinel-2 (divergence numérique)	Filtrer comme outlier
EVI < -1.5	Sentinel-2	Filtrer comme outlier
NDVI < -0.2 ou > 1.0	Sentinel-2 (corruption)	Très rare, filtrer si présent
VV < -30 dB	Sentinel-1 (eau, pixel bord)	Filtrer si en masse
VV > 0 dB	Sentinel-1 (réflexion spéculaire)	Vérifier (sol gelé, eau)
pH = 0	SoilGrids (nodata)	Imputer par voisin
PRECTOTCORR < 0	NASA POWER (artefact)	Remplacer par 0

15. Index alphabétique des colonnes principales

Colonne	Source	Section
amplitude_therm	NASA POWER	7.4
bdod_*	SoilGrids	8.2
bilan_hydrique_cumul	NASA POWER	7.4
cec_*	SoilGrids	8.2
cfvo_*	SoilGrids	8.2
clay_*	SoilGrids	8.2
code_cultu	RPG	6.3
commune	RPG	6.3
date	NASA POWER	7.5
departement	RPG / NASA POWER	6.3 / 7.5

et0 / et0_cumul	NASA POWER	7.4
EVI / EVI_*	Sentinel-2	9.3 - 9.6
gdd_base0_cumul	NASA POWER	7.4
gdd_base5_cumul	NASA POWER	7.4
geometry	RPG (geojson)	6.3
harvest_date / harvest_doy	CéréObs	5.5
id_parcel	RPG	6.3
jours_chauds_cumul	NASA POWER	7.4
latitude	RPG	6.3
longitude	RPG	6.3
n_images	Sentinel-2	9.5
NDVI / NDVI_*	Sentinel-2	9.3 - 9.6
NDWI / NDWI_*	Sentinel-2	9.3 - 9.6
nitrogen_*	SoilGrids	8.2
ocd_* / ocs_*	SoilGrids	8.2
parcelle_uid	Toutes (clé)	3.3
phh2o_*	SoilGrids	8.2
pluie_30j	NASA POWER	7.4
PRECTOTCORR	NASA POWER (brut)	7.3
PS	NASA POWER (brut)	7.3
rayonnement_cumul	NASA POWER	7.4
RH2M	NASA POWER (brut)	7.3
sand_*	SoilGrids	8.2
scene_date	S2 raw / S1 raw	9.6 / 10.5
silt_*	SoilGrids	8.2
soc_*	SoilGrids	8.2
surf_parc	RPG	6.3
T2M / T2M_MIN / T2M_MAX	NASA POWER (brut)	7.3
VH	Sentinel-1	10.5
VV	Sentinel-1	10.5
VV_VH_ratio	Sentinel-1	10.5
window_days	Sentinel-2 (composites)	9.5
window_start	Sentinel-2 (composites)	9.5
WS2M	NASA POWER (brut)	7.3
wv0010_* / wv1500_*	SoilGrids	8.2
year	Toutes (clé)	3.3

16. Datasets Kaggle publics

Toutes les sources raw sont déposées publiquement sur Kaggle (compte rgislikassi) sous licence CC BY 4.0 :

Source	URL Kaggle
1. Céré'Obs (cible)	kaggle.com/datasets/rgislikassi/cereb-dataset
2. RPG parcelles	kaggle.com/datasets/rgislikassi/parcele-ble-cvl-300
3. Météo NASA POWER	kaggle.com/datasets/rgislikassi/meteo-centre-vale-de-loire-2019-2024-nasapower
4. SoilGrids	kaggle.com/datasets/rgislikassi/soil-features-centre-val-de-loire-1500-parcels
5. Sentinel-2 (indices)	kaggle.com/datasets/rgislikassi/sentinel-2-indices-cvl-1500-wheat-parcels
6. Sentinel-1 SAR	kaggle.com/datasets/rgislikassi/sentinel-1-sar-backscatter-cvl-1500-wheat-parcels

17. Documents associés

Document	Contenu	Usage
Introduction Agronomique	Vulgarisation des concepts (blé, satellites, ML)	Lecture préalable pour néophytes
Master Dataset Report	Méthodologie complète de bout-en-bout	Comprendre les choix de conception
Data Dictionaries individuels	6 PDFs spécifiques par source	Détails techniques par source
Dataset Reports individuels	6 PDFs spécifiques par source	Méthodologie d'acquisition par source
EDA Reports	Analyse exploratoire Sentinel-2 et Sentinel-1	Validation qualité données

18. Citation et licence

Licence du Master Dataset : CC BY 4.0 (Creative Commons Attribution 4.0 International). Libre réutilisation avec attribution.

Citation recommandée :

Kassi R. (2025). *Multi-source Sentinel-1/2 + climate + soil dataset for winter wheat harvest prediction in Centre-Val de Loire, France (2020-2024)*. Master's thesis, Indrashil University. Available on Kaggle: kaggle.com/rgislikassi

19. Crédits sources

Source	Citation officielle
Sentinel-2	ESA Copernicus Programme — Sentinel-2 Mission
Sentinel-1	ESA Copernicus Programme — Sentinel-1 Mission
Google Earth Engine	Gorelick et al. (2017), Remote Sensing of Environment, 202.
NASA POWER	NASA Langley Research Center (LaRC) POWER Project
SoilGrids	Poggio et al. (2021), SOIL 7:217–240. ISRIC World Soil Information
RPG	IGN + Ministère de l'Agriculture — Registre Parcellaire Graphique
Céré'Obs	FranceAgriMer + Arvalis Institut du végétal

