

Introduction Agronomique

Comprendre le blé d'hiver, sa culture et son suivi par satellite

DOCUMENT PÉDAGOGIQUE

Mémoire de Master

Prédiction de la fenêtre de récolte par Machine Learning

Blé d'hiver · Centre-Val de Loire · France

Université Indrashil — 2025

Encadrants : Dr. Vishvjit Thakar, Dr. Doreid Ammar

À qui s'adresse ce document ?

Ce document est volontairement pédagogique. Il s'adresse à toute personne qui souhaite comprendre ce projet sans avoir de prérequis en agronomie, en télédétection ou en machine learning. Tu n'as pas besoin d'être agronome ou ingénieur pour le lire — chaque concept est expliqué depuis le début, avec des exemples concrets et des schémas.

Pourquoi un tel document ?

Notre projet combine plusieurs domaines techniques qui ne sont pas familiers à tout le monde :

- 🌾 **L'agronomie** : comprendre comment pousse le blé, ses stades de développement, ses besoins
- 🛰️ **La télédétection** : comment des satellites observent les cultures depuis l'espace
- 📡 **Le radar SAR** : une technologie différente des satellites optiques, qui "voit" à travers les nuages
- 🌱 **Les sciences du sol** : pourquoi le sol influence la croissance des plantes
- ☀️ **La climatologie** : les variables météo qui pilotent la croissance
- 🤖 **Le machine learning** : comment des modèles peuvent apprendre à prédire des dates

Au lieu de supposer que tu connais ces sujets, on les introduit ici de manière complète et accessible.

Structure du document

PARTIE I — Le blé et son cycle

1. Qu'est-ce que le blé d'hiver ?
2. Le cycle phénologique du blé
3. L'échelle BBCH — un langage universel
4. Le contexte français : Centre-Val de Loire

PARTIE II — Les facteurs qui influencent le blé

5. Le sol et ses propriétés
6. Le climat et la météo
7. Les pratiques agricoles

PARTIE III — La télédétection satellite

8. Comment "voient" les satellites ?
9. Les indices de végétation (NDVI, EVI, NDWI)
10. Le radar SAR (Sentinel-1)
11. Le problème des nuages

PARTIE IV — La récolte et sa prédiction

12. Qu'est-ce que la "récolte optimale" ?
13. Pourquoi prédire la date de récolte ?
14. Les signaux satellites de la récolte

PARTIE V — L'approche Machine Learning

15. Pourquoi le ML ?
16. Les sources de données combinées
17. Glossaire complet

PARTIE I — Le blé et son cycle

1. Qu'est-ce que le blé d'hiver ?

1.1 Une céréale stratégique

Le **blé tendre** (*Triticum aestivum*) est la céréale la plus cultivée au monde. C'est l'ingrédient principal du pain, des pâtes, de la pâtisserie et de nombreux autres produits. En France, le blé représente environ **5 millions d'hectares** de surface cultivée chaque année — soit l'équivalent de la moitié du territoire de la Belgique entièrement dédié au blé.

Définition — Blé tendre : espèce de céréale (*Triticum aestivum*) utilisée principalement pour la farine, le pain et les pâtisseries. On l'oppose au "blé dur" (*Triticum durum*) utilisé pour les pâtes et la semoule. Dans notre projet, on travaille uniquement avec le blé tendre.

1.2 "Blé d'hiver" — pourquoi ce nom ?

Il existe deux grandes catégories de blé :

Type	Semis	Récolte	Particularité
Blé d'hiver	Octobre–Novembre	Juillet	Besoin de froid pour fleurir (vernalisation)
Blé de printemps	Février–Mars	Août	Pas besoin de froid, cycle plus court

Le **blé d'hiver** est largement majoritaire en France (95% des surfaces). On le sème **en automne**, il passe l'hiver sous forme de jeunes plantes (10-15 cm de haut), puis reprend sa croissance au printemps pour atteindre 80-110 cm avant la récolte.

Exemple concret : en Centre-Val de Loire (notre zone d'étude), un blé d'hiver typique sera semé fin octobre 2019, passera l'hiver à grandir lentement, fera ses épis au printemps 2020, et sera récolté début juillet 2020. On parle donc de la "saison 2020" pour ce cycle complet.

1.3 Pourquoi étudier le blé spécifiquement ?

Le blé d'hiver est particulièrement intéressant pour notre projet de prédiction de récolte pour plusieurs raisons :

- **Importance économique majeure** : prédire la date optimale = optimiser des millions d'hectares
- **Cycle long et bien étudié** : ~9 mois entre semis et récolte, beaucoup de données disponibles
- **Sensibilité aux conditions** : météo, sol, et stress hydrique influencent fortement la date de maturité
- **Suivi satellite efficace** : les champs de blé sont grands et homogènes, idéal pour la télédétection
- **Données de référence disponibles** : la France a un service public (CéréObs) qui suit les dates de récolte chaque année

2. Le cycle phénologique du blé

Définition — Phénologie : étude du calendrier des phénomènes naturels chez les plantes : quand elles germent, quand elles fleurissent, quand elles mûrissent. La phénologie répond à la question *"qu'est-ce qui se passe et quand ?"* dans le cycle de vie d'une plante.

2.1 Les grandes étapes du cycle

De son semis à sa récolte, un grain de blé traverse **7 étapes principales**. Voici le voyage d'un grain semé en octobre :




Figure 1.1 — Les 7 grandes étapes du cycle du blé d'hiver, avec le signal NDVI typique mesuré par satellite en dessous. Le NDVI atteint son maximum à l'épiaison-floraison puis chute brutalement avec la maturation et la récolte.

2.2 Détail de chaque étape

Étape 1 — Semis (octobre)

Le grain de blé est semé dans le sol travaillé par l'agriculteur, à environ 2-3 cm de profondeur. À ce stade, depuis l'espace, on ne voit qu'un **sol nu** brun-clair.

Étape 2 — Levée (octobre-novembre)

Le grain germe et produit ses premières feuilles vertes (3-4 feuilles). La plante mesure 5-10 cm. Le satellite commence à détecter de la **verdure épars** sur le champ.

Étape 3 — Tallage (décembre-février)

La plante produit des **"talles"**, c'est-à-dire des pousses latérales depuis sa base. Au lieu d'avoir une seule tige, le blé en aura 3-5 par plante. C'est une phase de **croissance lente** pendant l'hiver. La couverture verte du champ s'étoffe progressivement.

Définition — Talle : pousse secondaire qui émerge à la base de la plante. Chaque talle pourra produire son propre épi. Le tallage détermine donc en grande partie le nombre d'épis par mètre carré — un facteur clé du rendement final.

Étape 4 — Montaison (mars-avril)

La tige principale s'allonge rapidement (1-2 cm par jour). La plante passe de 15-20 cm à 60-80 cm en quelques semaines. Le champ devient **uniformément vert et dense**. C'est le début de la phase "explosive" qui mène à la production de l'épi.

Étape 5 — Épiaison (mai)

L'épi sort de la gaine de la dernière feuille et devient visible. C'est un **moment crucial** : le nombre de grains par épi est désormais déterminé. La plante atteint sa hauteur maximale (80-110 cm). C'est généralement à ce stade que le NDVI atteint son **maximum**.

Étape 6 — Floraison (fin mai - mi-juin)

Les fleurs minuscules à l'intérieur de l'épi s'ouvrent brièvement (souvent 3-5 jours seulement) et le pollen est libéré. C'est le moment de la **fécondation** qui produira les grains. Le NDVI est encore élevé mais commence à diminuer.

Étape 7 — Maturation et récolte (juin-juillet)

Les grains se remplissent (phase de "remplissage du grain"), puis la plante **sénesce** (elle jaunit) au fur et à mesure que les grains durcissent. Quand le taux d'humidité du grain descend sous **14-15%**, l'agriculteur peut récolter. Le champ passe alors du vert au doré-jaune, puis la moissonneuse-batteuse fait apparaître le **sol nu**.

Concept clé : le moment de la récolte n'est pas une date fixe — il dépend de l'humidité du grain, qui dépend elle-même de la météo, du sol, et de la variété cultivée. C'est pour ça que prédire la "date optimale" est complexe et nécessite plein de données.

2.3 Vitesse de développement et "degrés-jours"

Tu as peut-être remarqué une chose étrange : entre l'étape 3 (tallage en décembre) et l'étape 4 (montaison en mars), il s'écoule **3 mois**. Mais entre l'étape 4 et 7 (montaison à récolte), il ne se passe que **3-4 mois** aussi, alors que la plante fait beaucoup plus de transformations. Pourquoi ?

La réponse est dans la **température**. Une plante ne pousse pas avec le temps qui passe, mais avec la **chaleur accumulée**. En hiver, il fait froid, et la plante grandit très lentement. Au printemps et en été, la chaleur s'accumule, et la croissance s'accélère.

Définition — Degré-jour de croissance (GDD) : mesure de chaleur accumulée par la plante. Pour le blé, on calcule chaque jour : $GDD = (T_{max} + T_{min}) / 2 - T_{base}$, où $T_{base} = 0^{\circ}\text{C}$ (pour le blé). On **cumule** ensuite ces valeurs sur toute la saison. Le blé doit accumuler environ **2200°C·jours** de la levée à la récolte.

Exemple chiffré : si une journée a une température max de 15°C et min de 5°C, le GDD du jour est : $(15+5)/2 - 0 = 10^{\circ}\text{C·jours}$. Si tu accumules 10°C·jours par jour pendant 220 jours, tu atteins 2200°C·jours — c'est environ le seuil de maturité du blé. Mais en réalité, on a des jours plus froids (hiver, ~3°C·jours) et des jours plus chauds (été, ~20°C·jours), donc le temps réel varie selon les conditions climatiques.

2.4 Pourquoi la phénologie est-elle si importante ?

Comprendre les stades du blé est essentiel pour **3 raisons** :

1. **Les besoins changent** — Le blé a besoin de plus d'eau pendant la montaison qu'à la levée.
2. **Les risques changent** — Le gel en avril (pendant la montaison) tue les jeunes épis, alors qu'en décembre c'est sans conséquence.
3. **La récolte se prépare** — On ne récolte qu'à la phase 7. Tout ce qui précède détermine si on récoltera tôt (juin) ou tard (août).

2.5 Le concept de "fenêtre optimale de récolte"

Quand le blé est mûr, l'agriculteur a une **fenêtre de temps** pour récolter — pas une date fixe. Cette fenêtre dure typiquement **7-15 jours**, pendant lesquels :

- Le grain a la bonne humidité (entre 12% et 15%)
- La tige est suffisamment sèche pour être coupée proprement
- Les conditions météo sont favorables (pas de pluie)
- L'agriculteur a la disponibilité de sa moissonneuse

Pourquoi cette fenêtre est-elle importante ?

-  **Récolter trop tôt** : grain trop humide → coûts de séchage élevés, risque de moisissure
-  **Récolter trop tard** : grain trop sec → pertes en battage, risque de germination sur pied si pluie
-  **Récolter au bon moment** : qualité maximale, rendement optimal, coûts minimaux

Notre projet vise précisément à **prédire cette fenêtre optimale** pour chaque parcelle, en utilisant les données satellite, météo et sol.

3. L'échelle BBCH — un langage universel

3.1 Pourquoi une échelle standardisée ?

Imagine qu'un agriculteur français dise "mon blé est en montaison" et qu'un chercheur allemand dise "mein Weizen ist in der Schossphase". Comment être sûrs qu'ils parlent du même stade ? Et comment écrire des programmes informatiques qui comprennent ces termes flous ?

C'est pour résoudre ce problème que l'**échelle BBCH** a été inventée. C'est une échelle numérique standardisée, utilisée mondialement, qui découpe le cycle de toute culture en **10 stades principaux** (0 à 9), eux-mêmes subdivisés en **10 sous-stades** (0 à 9), pour un total de 100 codes possibles (00 à 99).

Définition — BBCH : acronyme allemand de *Biologische Bundesanstalt, Bundessortenamt und CHemische Industrie* (les trois institutions qui ont créé cette échelle dans les années 1990). C'est aujourd'hui le standard international pour décrire les stades phénologiques de centaines d'espèces cultivées.

3.2 L'échelle BBCH appliquée au blé

Voici les principaux codes BBCH pour le blé d'hiver, organisés par stade principal :

Code	Stade principal	Description
0	Germination	Du grain sec à la pointe de coléoptile au-dessus du sol
00		Grain sec
09		Levée : pointe de la première feuille visible
1	Feuilles	De 1 à 9 feuilles déployées
11		1 feuille déployée
13		3 feuilles déployées (souvent ≈ levée terminée)
2	Tallage	Émergence des talles latérales
21		1 talle visible
25		5 talles (souvent en hiver)
3	Montaison	La tige s'allonge
31		1er nœud visible (mars-avril)
37		Dernière feuille pointe
39		Dernière feuille étalée
5	Épiaison	L'épi sort de la gaine foliaire
51		Début sortie de l'épi
55		Moitié de l'épi sortie
59		Épi totalement sorti
6	Floraison	Anthèse — les fleurs s'ouvrent
61		Début floraison
65		Pleine floraison (50% des fleurs ouvertes)

69		Fin floraison
7	Remplissage du grain	Le grain grossit et accumule l'amidon
71		Grain laiteux (liquide blanc à l'intérieur)
75		Stade laiteux moyen
8	Maturation	Le grain durcit, la plante jaunit
83		Grain pâteux mou
87		Grain pâteux dur
9	Sénescence	Plante sèche, prête à récolter
91		Grain dur, plante encore verte par endroits
92		Grain mûr, casse sous l'ongle → RÉCOLTE ★
99		Grain en post-récolte

Exemple concret : dans le service public Céré'Obs, la "date de récolte 50%" correspond au stade BBCH 92 atteint dans **la moitié des parcelles d'une région**. C'est cette date qu'on utilise comme cible (target) dans notre projet ML.

3.3 Le lien BBCH ↔ NDVI

Le NDVI mesuré par satellite n'est **pas** directement un stade BBCH, mais il est étroitement corrélé. Voici la correspondance typique :

Stade BBCH	NDVI typique	Interprétation
00–09 (semis-levée)	0.15 – 0.30	Sol nu dominant, peu de végétation
13–25 (jeunes feuilles, tallage)	0.30 – 0.55	Couverture verte partielle
30–39 (montaison)	0.55 – 0.75	Couverture verte dense
50–69 (épiaison-floraison)	0.75 – 0.90	Maximum de la saison
70–79 (remplissage)	0.65 – 0.80	Encore vert, mais sénescence commence
80–89 (maturation)	0.40 – 0.65	Jaunissement progressif
90–99 (sénescence/récolte)	0.15 – 0.35	Plante sèche puis sol nu

Insight pour le ML : le NDVI ne dit pas "BBCH 92" mais sa **chute brutale** de 0.75 à 0.35 indique la transition maturation → récolte. C'est précisément ce que notre modèle cherchera à détecter !

4. Le contexte français : Centre-Val de Loire

4.1 Pourquoi cette région ?

Notre projet se concentre sur la région **Centre-Val de Loire (CVL)**, qui couvre le centre de la France entre Paris et Bordeaux. Cette région a été choisie pour **4 raisons** :

1. **Région céréalière majeure** : la CVL est l'une des plus grosses productrices de blé en France, avec environ 500 000 hectares de blé chaque année.
2. **Sols variés** : la "Beauce" (nord-est, sols limoneux profonds) et le "Berry" (sud, sols plus argileux) offrent une diversité agronomique intéressante.
3. **Climat tempéré** : conditions favorables au blé d'hiver, pas trop chaud ni trop froid.
4. **Données de référence disponibles** : CéréObs publie chaque année les dates de récolte pour cette région.

4.2 Les 6 départements de la CVL

La région Centre-Val de Loire est composée de **6 départements**. Notre projet couvre tous les six :

Code	Nom	Chef-lieu	Particularité agronomique
28	Eure-et-Loir	Chartres	Cœur de la Beauce, sols limoneux profonds
45	Loiret	Orléans	Beauce + vallée de la Loire
41	Loir-et-Cher	Blois	Sologne (sablonneux) + Beauce sud
37	Indre-et-Loire	Tours	Vallées et plateaux mixtes
18	Cher	Bourges	Champagne berrichonne, sols argileux
36	Indre	Châteauroux	Boischaut, sols plus contraignants

4.3 La Beauce — "grenier à blé" de la France

Quand on parle de blé en CVL, on parle souvent de la **Beauce**. C'est une vaste plaine sédimentaire au nord-est de la région (départements 28 et 45 principalement). Ses caractéristiques en font un terroir céréaliier exceptionnel :

- **Sols limoneux profonds** : faciles à travailler, bonne rétention en eau
- **Topographie plate** : permet l'agriculture mécanisée à grande échelle
- **Climat océanique tempéré** : pluies réparties sur l'année, étés pas trop secs
- **Tradition céréalière** : terres exploitées pour le blé depuis le Moyen Âge

Exemple historique : dès le 13^{ème} siècle, la Beauce alimentait Paris en blé. Aujourd'hui, elle produit en moyenne **7-9 tonnes de blé par hectare**, soit parmi les meilleurs rendements mondiaux. À titre de comparaison, la moyenne mondiale est de 3-4 t/ha.

4.4 Notre échantillon : 1500 parcelles

Pour notre étude, on a sélectionné **1500 parcelles de blé** dans cette région :

- **300 parcelles par année** (de 2020 à 2024)
- **Surface minimum de 1 hectare** (pour éviter les très petites parcelles dont le signal satellite serait bruité)
- Réparties sur les **6 départements**
- Sélectionnées au hasard (random sampling) à partir du **RPG** (Registre Parcellaire Graphique, une base de données publique de toutes les parcelles agricoles de France)

Définition — Parcelle agricole : unité élémentaire d'exploitation agricole. C'est un terrain homogène, cultivé d'une seule manière (une seule espèce, une seule conduite) par un exploitant. Une exploitation agricole peut compter plusieurs parcelles, dispersées géographiquement.

PARTIE II — Les facteurs qui influencent le blé

Le développement et la date de récolte du blé ne dépendent pas que du calendrier. Trois grandes familles de facteurs entrent en jeu :

1. 🌱 **Le sol** (statique) : composition, structure, capacité de rétention en eau
2. ☀️ **La météo** (dynamique) : température, pluies, ensoleillement
3. 🧑🌾 **Les pratiques agricoles** (semi-contrôlées) : date de semis, variété, fertilisation

Comprendre ces facteurs est essentiel pour comprendre **pourquoi** on collecte les données qu'on collecte.

5. Le sol et ses propriétés

5.1 Le sol n'est pas qu'un support

Pour un débutant, "la terre" peut sembler être juste un endroit où on plante. En réalité, le sol est un système complexe avec ses propres caractéristiques, qui influencent fortement comment et quand un blé va se développer.

Définition — Sol : milieu vivant composé de particules minérales (sable, limon, argile), de matière organique (résidus végétaux et animaux décomposés), d'eau, d'air, et d'organismes vivants (bactéries, vers de terre, champignons). C'est **l'interface** entre la plante et son environnement minéral.

5.2 La texture : sable, limon, argile

Le sol est composé de particules de tailles différentes. Selon leurs proportions, on définit trois grandes **textures** :




Figure 5.1 — Les 3 fractions texturales du sol. Du plus gros (sable, grains visibles) au plus fin (argile, plaquettes microscopiques). Leurs proportions déterminent comment l'eau circule dans le sol.

Texture	Composition	Comportement pour le blé
Sableux	> 70% sable	Sol pauvre, eau s'évacue vite, blé souffre en cas de sécheresse
Limoneux	Mix équilibré, dominante limon	★ Idéal pour le blé : retient bien l'eau, facile à travailler
Argileux	> 35% argile	Retient beaucoup d'eau mais difficile à travailler, peut s'asphyxier
Limono-argileux	Mix dominé par limon et argile	Très bon pour le blé (cas de la Beauce)

5.3 La capacité de rétention en eau (AWC)

Définition — Capacité de rétention en eau utile (AWC = Available Water Capacity) : quantité d'eau que le sol peut retenir et fournir à la plante. Elle s'exprime en **mm d'eau par mètre de sol**. Un sol avec AWC = 150 mm/m signifie que dans 1 mètre de profondeur, il peut fournir 150 mm de pluie équivalente à la plante.

L'AWC est **cruciale** pour le blé. Si le sol stocke beaucoup d'eau (sol limoneux profond), le blé survivra à des périodes sèches en mai-juin. Si l'AWC est faible (sol sableux), une sécheresse au printemps peut faire chuter le rendement de 30-50% et avancer la date de récolte.

Exemple concret : en avril 2020, une parcelle en Beauce (AWC ~200 mm/m) et une parcelle en Sologne (AWC ~80 mm/m) reçoivent une semaine sans pluie avec 25°C. La Beauce a encore 150 mm de réserve dans son sol → le blé continue normalement. La Sologne n'a plus que 30 mm → le blé commence à stresser, ses feuilles se ferment, sa croissance ralentit, la maturation s'avance de quelques jours.

5.4 Autres propriétés du sol qu'on mesure

Dans notre projet, on collecte **13 propriétés du sol** via la base SoilGrids, mesurées à **3 profondeurs** (0-5 cm, 5-15 cm, 15-30 cm). En voici les principales :

Propriété	Unité	Importance pour le blé
Sand, Silt, Clay	% massique	Texture du sol — base de tout
SOC (Soil Organic Carbon)	g/kg	Matière organique = fertilité naturelle
pH (water)	0-14	Acidité ; le blé préfère pH 6-7 (légèrement acide)
CEC (Cation Exchange Capacity)	cmol/kg	Capacité du sol à retenir les nutriments
Nitrogen	g/kg	Azote — nutriment principal pour le blé
Bulk density	kg/dm ³	Compacité du sol — affecte enracinement
Coarse fragments	cm ³ /dm ³	% de cailloux — limite le volume utile

Pourquoi 3 profondeurs ? Les racines du blé descendent jusqu'à 1-1.5 m, mais l'essentiel de l'activité se passe dans les 30 premiers cm. On échantillonne donc à 3 niveaux pour capturer la zone réellement utilisée par les racines.

6. Le climat et la météo

6.1 Les variables qui comptent pour le blé

La météo influence chaque jour le développement du blé. Pour notre projet, on collecte des données quotidiennes sur **8 variables principales**, dont on dérive 22 indicateurs agronomiques. Voyons les principales :

La température

C'est la variable la plus importante. La température détermine la vitesse de croissance via les degrés-jours (vu en section 2.3).

- **T_min** (minimale du jour) : nuit froide = risque de gel
- **T_max** (maximale) : chaude = développement rapide, mais > 30°C peut stresser
- **T_moy** = $(T_{\min} + T_{\max}) / 2$: base pour calculer le GDD

Exemple : en avril 2020, la CVL a connu une vague de chaleur précoce (T_max moyenne 22°C). Le GDD cumulé a augmenté plus vite que la normale, ce qui a **avancé la date de récolte** de 5-7 jours par rapport à 2021 (avril plus frais).

Les précipitations (pluie)

Sans eau, pas de plante. Mais l'eau a un double effet :

Période	Pluie favorable	Pluie défavorable
Automne (semis-levée)	Modérée pour germination	Excès → semis impossible
Hiver (tallage)	Recharge des réserves du sol	—
Printemps (montaison)	Essentielle pour la croissance	Sécheresse → rendement chute
Été (maturation)	—	Pluie à la récolte → grain humide, qualité dégradée

L'ensoleillement (rayonnement solaire)

Le rayonnement solaire (mesuré en MJ/m²/jour) est l'**énergie** qui fait fonctionner la photosynthèse. Plus il y a de soleil, plus la plante produit de biomasse — à condition d'avoir aussi assez d'eau.

L'humidité de l'air et le vent

Combinés à la température, ils déterminent à quelle vitesse l'eau s'évapore du sol et de la plante, ce qui nous amène au concept clé suivant :

6.2 L'évapotranspiration de référence (ET0)

Définition — ET0 : évapotranspiration de référence, ou "demande évaporative" de l'atmosphère. C'est la quantité d'eau (en mm) qu'une culture théorique de gazon bien arrosé évaporerait dans des conditions données. C'est en quelque sorte la "soif" de l'atmosphère.

ET0 est calculé par une formule complexe (Penman-Monteith, FAO-56) qui combine température, humidité, vent et rayonnement. Une journée chaude, sèche et venteuse aura un ET0 élevé (5-7 mm/jour), tandis qu'une journée fraîche et humide aura un ET0 faible (1-2 mm/jour).

6.3 Le bilan hydrique

Le concept du **bilan hydrique** permet de savoir si une parcelle a "soif" :

Bilan hydrique = **Pluie tombée** – **ET0 demandé**

Si positif : il a plu plus que ce que l'atmosphère "veut" → sol s'humidifie

Si négatif : il a plu moins que la demande → sol s'assèche

Exemple : en mai 2020, une parcelle reçoit 30 mm de pluie sur le mois. L'ET0 cumulé du mois est de 110 mm. Bilan hydrique = 30 – 110 = **-80 mm**. C'est très négatif → le sol s'est asséché de 80 mm. Si le sol avait 150 mm de réserve, il en reste 70 → le blé n'a pas (encore) souffert.

6.4 Pourquoi la météo n'est-elle pas suffisante seule ?

La météo influence fortement quand le blé sera mûr, mais elle ne dit pas **tout** :

- Deux parcelles voisines (même météo) peuvent avoir des dates de récolte différentes selon leur sol
- La variété de blé semée a aussi un impact (précoce ou tardive)
- L'historique cultural (rotation, fertilisation) influence la santé du blé

C'est pourquoi notre projet combine **météo + sol + observations satellites** : chaque source apporte une information différente et complémentaire.

7. Les pratiques agricoles

7.1 Ce que l'agriculteur décide

L'agriculteur fait de nombreux choix qui influencent le développement du blé. Les principaux :

Décision	Quand ?	Impact
Variété de blé	Été précédent	Précoce ou tardive ; résistance au stress
Date de semis	Octobre-novembre	Semer tôt → blé plus avancé au printemps
Densité de semis	Semis	250-400 grains/m ² selon contexte
Fertilisation	Hiver et printemps	Azote, phosphore, potassium
Traitements phytosanitaires	Printemps	Contrôle maladies, ravageurs
Date de récolte	Juillet	Décision finale selon humidité du grain

7.2 La rotation culturale

Une parcelle ne porte pas du blé chaque année. Les agriculteurs alternent les cultures pour :

- **Préserver la fertilité du sol** (légumineuses fixent l'azote)
- **Casser le cycle des maladies** spécifiques au blé
- **Optimiser le revenu** (rotations économiquement intéressantes)

Rotation typique en CVL : Colza → Blé d'hiver → Orge d'hiver → Pois → Blé d'hiver. Chaque parcelle ne porte du blé qu'environ **1 année sur 2-3**. Dans notre projet, on a vérifié que la persistance du blé d'une année sur l'autre est de seulement **17%** — c'est pour ça qu'on échantillonne 300 nouvelles parcelles chaque année plutôt que les mêmes 300 parcelles 5 fois.

7.3 Ce qu'on NE collecte PAS dans notre projet

Pour rester réaliste et reproductible, notre projet n'utilise **aucune** donnée individuelle d'agriculteur :

- ❌ Pas de date de semis individuelle (privée)
- ❌ Pas de variété cultivée (privée)
- ❌ Pas de fertilisation appliquée (privée)
- ❌ Pas de pratique de récolte individuelle (privée)

À la place, on utilise uniquement des **données ouvertes et observables depuis l'extérieur** : satellites (NDVI, SAR), météo publique, sol public, et la **date de récolte 50% régionale** publiée par CéréObs.

C'est une force du projet : en n'utilisant que des données ouvertes, notre méthode pourra être **répliquée** à n'importe quelle région ou n'importe quel pays sans avoir à demander à chaque agriculteur ses pratiques.

PARTIE III — La télédétection satellite

Voici probablement la partie la plus exotique pour un débutant : comment on utilise des satellites spatiaux pour suivre la croissance du blé. On va décortiquer ça en 4 sections.

8. Comment "voient" les satellites ?

8.1 Le principe de la télédétection

Définition — Télédétection : ensemble des techniques permettant d'observer la Terre depuis l'espace (ou un avion, ou un drone) sans contact physique avec la cible. Le mot vient du grec *tele* (à distance) et du latin *detectio* (action de découvrir).

Tout objet sur Terre **renvoie** de la lumière vers l'espace — soit en réfléchissant la lumière du soleil (capteurs **passifs**), soit en réfléchissant un signal envoyé par le satellite lui-même (capteurs **actifs**, comme le radar).

Un satellite équipé d'un capteur (caméra spéciale ou antenne radar) mesure cette lumière renvoyée et la transforme en une **image numérique**. Selon la longueur d'onde mesurée, on obtient des informations différentes sur les surfaces.

8.2 Les longueurs d'onde — au-delà de ce qu'on voit

L'œil humain ne voit qu'une **toute petite portion** du spectre électromagnétique : la lumière visible (rouge, vert, bleu). Les satellites mesurent bien plus que ça.




Figure 8.1 — Le spectre électromagnétique et les bandes utilisées par les satellites. L'œil humain ne voit que la bande visible (400-700 nm). Pour le suivi du blé, on utilise surtout le proche infrarouge (NIR) et les micro-ondes (radar).

8.3 Pourquoi le proche infrarouge (NIR) est-il magique ?

Les plantes vertes ont une propriété très particulière en NIR : elles le **réfléchissent massivement**. Beaucoup plus que ce qu'elles réfléchissent en lumière visible.

Pourquoi ? La **chlorophylle** (qui donne la couleur verte aux plantes) **absorbe** les photons rouges pour faire la photosynthèse. En NIR, elle ne peut rien faire — la cellule renvoie ces photons. Plus une plante est en bonne santé et photosynthétiquement active, plus elle absorbe de rouge ET plus elle réfléchit de NIR.

Principe-clé : en comparant ce qu'une plante **absorbe** (rouge) à ce qu'elle **réfléchit** (NIR), on a une mesure indirecte de son activité photosynthétique. C'est la base du NDVI.

8.4 Les satellites qu'on utilise

Pour notre projet, on utilise **deux familles de satellites**, toutes deux du programme européen Copernicus de l'Agence Spatiale Européenne (ESA) :

Satellite	Type	Bandes	Revisite	Résolution
Sentinel-2	Optique passif	13 bandes (visible, NIR, SWIR)	5 jours	10-20 m
Sentinel-1	Radar SAR actif	Bande C (5.4 GHz)	6 jours	10 m

Ces deux satellites sont **gratuits** et leurs données sont accessibles librement depuis 2014 (Sentinel-1) et 2015 (Sentinel-2). Une révolution pour la recherche en télédétection.

9. Les indices de végétation (NDVI, EVI, NDWI)

9.1 Le NDVI — l'indice star

Définition — NDVI (Normalized Difference Vegetation Index) : indice qui mesure la "verdeur" et la vigueur de la végétation. Sa formule est :

$$\text{NDVI} = (\text{NIR} - \text{Rouge}) / (\text{NIR} + \text{Rouge})$$

NIR = réflectance dans le proche infrarouge

Rouge = réflectance dans le rouge visible

Le NDVI varie entre **-1 et +1** :

Valeur	Surface	Interprétation
< 0	Eau	L'eau absorbe à la fois rouge et NIR
0.0 – 0.15	Sol nu, rochers, sable	Pas de végétation
0.15 – 0.30	Végétation très clairsemée	Sol majoritaire visible
0.30 – 0.50	Végétation modérée	Jeune blé, prairies stressées
0.50 – 0.80	Végétation dense en croissance	Blé en pleine montaison
0.80 – 0.95	Pic de végétation	Blé à l'épiaison (max)
0.95 – 1.0	Quasi impossible	Erreur ou cas extrême

9.2 Pourquoi normaliser ?

Tu te demandes peut-être : pourquoi diviser (NIR – Rouge) par (NIR + Rouge) ? Pourquoi pas juste (NIR – Rouge) ?

La raison : la **normalisation** annule les effets de l'éclairement global. Imagine une parcelle photographiée à deux moments :


- **Moment 1** : ciel ensoleillé, beaucoup de lumière. NIR = 0.6, Rouge = 0.1.
- **Moment 2** : ciel partiellement nuageux. NIR = 0.3, Rouge = 0.05.

Sans normalisation, NIR – Rouge = 0.5 ou 0.25 → deux valeurs très différentes pour la **même plante** ! Avec normalisation :

- $\text{NDVI}(\text{M1}) = (0.6 - 0.1) / (0.6 + 0.1) = 0.5 / 0.7 = \mathbf{0.71}$
- $\text{NDVI}(\text{M2}) = (0.3 - 0.05) / (0.3 + 0.05) = 0.25 / 0.35 = \mathbf{0.71}$

Le NDVI est **identique** ! Le NDVI mesure une propriété **intrinsèque** de la plante, indépendamment de l'éclairement. C'est ce qui fait sa robustesse.

9.3 Le profil NDVI typique du blé sur une saison



Profil NDVI moyen d'une parcelle de blé d'hiver en Centre-Val de Loire

Figure 9.1 — Profil NDVI typique du blé d'hiver sur une saison complète. On voit clairement les 4 phases : implantation (NDVI bas), croissance active (montée), pic à l'épiaison-floraison, et chute brutale à la récolte.

9.4 Les autres indices : EVI et NDWI

EVI (Enhanced Vegetation Index)

L'EVI est une **amélioration du NDVI**, conçue pour mieux fonctionner sur :

- Les **végétations très denses** (où le NDVI sature autour de 0.85)
- Les **sols clairs visibles** (l'EVI corrige cet effet)
- Les **résidus atmosphériques**

Sa formule, plus complexe :

$$EVI = 2.5 \times (NIR - Rouge) / (NIR + 6 \times Rouge - 7.5 \times Bleu + 1)$$

L'EVI utilise **3 bandes** au lieu de 2 (NIR, Rouge, Bleu), et corrige les effets atmosphériques via la bande bleue. Pour notre projet, c'est une **information complémentaire** au NDVI.

NDWI (Normalized Difference Water Index)

Le NDWI utilise le SWIR (infrarouge à courte longueur d'onde) au lieu du Rouge :

$$NDWI = (NIR - SWIR) / (NIR + SWIR)$$

Le SWIR est **absorbé par l'eau**. Une plante bien hydratée renvoie peu de SWIR (NDWI élevé), une plante stressée renvoie plus de SWIR (NDWI bas). Le NDWI est donc un **indicateur de stress hydrique** de la plante.

Exemple : en juin, une parcelle a un NDVI encore élevé (0.65) mais un NDWI qui chute (0.10). Cela indique une plante qui **garde sa forme verte** mais **perd son eau** — un signe précoce de sénescence. Le NDWI peut détecter le stress avant le NDVI.

9.5 Pourquoi combiner les trois ?

Indice	Capture	Force	Faiblesse
NDVI	Verdure générale	Très robuste, standard	Sature en végétation dense
EVI	Vigueur (corrigée)	Mieux en pic de saison	Plus sensible aux artefacts
NDWI	Hydratation foliaire	Détecte stress précoce	Plus bruité que NDVI

Ensemble, ces 3 indices donnent une **vision plus complète** de l'état de la plante.

10. Le radar SAR (Sentinel-1)

10.1 Une technologie totalement différente

Jusqu'ici, on a parlé de satellites **optiques** (Sentinel-2) qui mesurent la lumière du soleil réfléchi par la Terre. Sentinel-1 utilise une approche **radicalement différente** : le radar.

Définition — SAR (Synthetic Aperture Radar) : radar à synthèse d'ouverture. Le satellite **émet** des ondes micro-ondes vers la Terre, et **mesure** l'écho qui revient. C'est un capteur **actif** (par opposition aux capteurs passifs qui mesurent juste la lumière reçue).

10.2 Comment fonctionne le radar SAR




Figure 10.1 — Comparaison entre Sentinel-2 (optique passif) et Sentinel-1 (SAR actif). Le SAR émet sa propre onde, qui traverse les nuages — un avantage majeur en hiver.

Le processus en 4 étapes :

- Le satellite **émet** une impulsion micro-onde vers la Terre (longueur d'onde ~5.6 cm, bande C)
- L'onde voyage vers la surface en quelques millisecondes
- Une partie de l'onde est **renvoyée** vers le satellite (rétrodiffusion)
- Le satellite **mesure** l'intensité de l'écho et le temps d'aller-retour

10.3 Pourquoi le radar fonctionne à travers les nuages

Les micro-ondes utilisées par Sentinel-1 (~5.6 cm de longueur d'onde) sont **beaucoup plus grandes** que les gouttelettes d'eau dans les nuages (~1-100 μm). Conséquence : les nuages sont **transparents** pour ces micro-ondes. L'onde radar passe à travers, atteint le sol, revient, sans être perturbée.

C'est l'inverse pour la lumière visible (~500 nm = 0.5 μm), qui est **plus petite** que les gouttelettes — elle est diffusée par les nuages, ne peut pas atteindre le sol, et le satellite optique ne voit qu'un toit blanc.

10.4 Ce que mesure le SAR : la rétrodiffusion (σ^0)

Définition — Rétrodiffusion σ^0 (sigma zéro) : coefficient de rétrodiffusion. C'est le pourcentage de l'énergie radar émise qui revient vers le satellite. Exprimé en décibels (dB).

Pour le blé, σ^0 varie typiquement de **-25 dB à -5 dB**. Plus la valeur est élevée (proche de 0), plus la surface renvoie d'énergie.

Qu'est-ce qui détermine l'intensité de la rétrodiffusion ?

Facteur	Effet sur σ^0
Rugosité de surface	Plus rugueux → plus de rétrodiffusion
Humidité du sol	Plus humide → plus de rétrodiffusion (eau réfléchit)
Structure verticale (canopée)	Tiges verticales → forte rétrodiffusion en VV
Volume de la canopée	Canopée dense → atténue le signal sol
Géométrie d'observation	Angle d'incidence affecte l'écho

10.5 Les polarisations VV et VH

Sentinel-1 émet et reçoit en deux **polarisations** (orientations de l'onde) :

- **VV** : émission verticale, réception verticale (co-polarisation)
- **VH** : émission verticale, réception horizontale (cross-polarisation)

Pourquoi est-ce intéressant ? Différentes structures réagissent différemment :

Polarisation	Sensible à	Pour le blé
VV	Surfaces, tiges verticales	Détecte le sol nu et la structure verticale
VH	Diffusion volumique (canopée)	Détecte la biomasse
VV/VH ratio	Densité de canopée	Chute quand canopée s'épaissit

10.6 La signature SAR du blé sur une saison

Le profil SAR du blé est **inverse** du profil NDVI :

- **Automne (semis)** : sol nu rugueux + débris → VV **élevé** (~-9 dB)
- **Hiver** : blé bas, peu de canopée → VV stable
- **Printemps (montaison)** : canopée se développe → VV **chute** (atténuation)
- **Mai (épiaison-floraison)** : canopée dense → VV **minimum** (~-13.5 dB)
- **Juin-juillet (récolte)** : canopée coupée → VV **remonte brutalement**

Signal de récolte SAR : la **remontée brutale** du VV (et du ratio VV/VH) juste après la récolte est un **marqueur direct** du passage de la moissonneuse. C'est l'un des signaux les plus précieux pour notre modèle ML !

11. Le problème des nuages

11.1 Pourquoi les nuages sont un problème

On l'a vu, les satellites **optiques** (Sentinel-2) ne peuvent pas "voir" à travers les nuages. Quand un nuage est entre le sol et le satellite, le capteur n'enregistre que le toit du nuage — aucune information sur le champ en dessous.

En France et en Europe centrale, c'est un problème **massif** en hiver :

Mois	% jours avec nuages denses	Conséquence pour Sentinel-2
Décembre	50-70%	1 image utile sur 3-4 passages
Janvier	50-70%	Idem
Février	40-60%	Légèrement meilleur
Mai	20-30%	Bonne couverture
Juillet	10-15%	Excellente couverture

11.2 Comment on gère ce problème

Notre projet utilise **3 stratégies complémentaires** :

1. **Masquage des nuages** : on utilise un algorithme (SCL — Scene Classification Layer) fourni par l'ESA qui identifie automatiquement les pixels nuages, ombres et neige. On les **exclut** avant de calculer les indices.
2. **Composites temporels** : on agrège plusieurs scènes sur une fenêtre (7 jours ou 15 jours) et on prend la médiane. Si une scène est nuageuse mais 3 autres sont claires, la médiane reflète les scènes claires.
3. **Complément SAR** : Sentinel-1 fonctionne **tout temps**. On a donc ~8 scènes SAR par parcelle par mois, même en hiver. Combiné à Sentinel-2, on couvre l'ensemble de la saison.




Figure 11.1 — Comparaison des densités de scènes valides entre Sentinel-2 (optique, sensible aux nuages) et Sentinel-1 (SAR, tout temps). S1 fournit ~8 scènes/mois **même en hiver**, là où S2 chute à 2-3.

Pourquoi cette combinaison est unique pour notre projet : peu d'études combinent S1 + S2 à l'échelle parcellaire sur plusieurs années. C'est l'une des forces méthodologiques de notre mémoire.

PARTIE IV — La récolte et sa prédiction

12. Qu'est-ce que la "récolte optimale" ?

12.1 Le grain doit être mûr ET sec

Quand l'agriculteur considère son blé mûr, il regarde deux choses :

1. **La maturité physiologique** : le grain a atteint sa taille et son poids définitifs. C'est typiquement **40-45 jours après la floraison**.
2. **L'humidité du grain** : à maturité physiologique, le grain contient encore ~40% d'eau. Il faut attendre que cette eau s'évapore naturellement pour atteindre 14-15% d'humidité.

Définition — Humidité du grain : pourcentage d'eau dans le grain par rapport à son poids total. À la récolte, on vise **12-15%**. Au-dessus → coûts de séchage. En-dessous → risque de casse au battage.

12.2 La fenêtre de récolte optimale

Pour le blé d'hiver en Centre-Val de Loire, la fenêtre optimale de récolte se situe typiquement entre le **début juillet et la mi-juillet**, mais elle varie selon :

- L'**année** (météo printanière et estivale)
- La **parcelle** (sol, exposition, variété)
- La **région** dans la CVL

Année	Date Céré'Obs 50%	Particularité météo
2020	3 juillet (DOY 185)	Printemps chaud, sec en avril-mai
2021	18 juillet (DOY 199)	Printemps frais, retard de 15 jours
2022	2 juillet (DOY 183)	Très chaud (canicule mai), récolte avancée
2023	3 juillet (DOY 184)	Conditions moyennes
2024	13 juillet (DOY 195)	Printemps humide, retard léger

Insight : sur 5 années, la date varie de **16 jours** (entre 2022 le plus précoce et 2021 le plus tardif). C'est exactement ce qu'on veut **prédire** : sera-t-on plus proche de 2022 ou de 2021 cette année ?

13. Pourquoi prédire la date de récolte ?

13.1 Les enjeux pour l'agriculteur

- **Logistique** : organiser sa moissonneuse-batteuse, ses chauffeurs, ses bennes
- **Coût** : louer la moissonneuse à la bonne semaine (les prix montent en haute saison)
- **Qualité** : récolter au pic de qualité → meilleur prix au kilo
- **Risque météo** : éviter une période pluvieuse annoncée

13.2 Les enjeux pour la filière

- **Coopératives** : préparer les silos de stockage, planifier les transports

- **Industriels** : anticiper les arrivages de matière première
- **Marchés** : la date de récolte influence les cours du blé
- **Statistiques nationales** : suivre la campagne agricole en temps réel

13.3 Les enjeux scientifiques

- **Comprendre le changement climatique** : si les récoltes s'avancent d'année en année, c'est un signal
- **Améliorer les variétés** : tester quelles variétés s'adaptent à quel climat
- **Politiques agricoles** : ajuster les programmes de soutien

14. Les signaux satellites de la récolte

Comment les satellites "voient" la récolte ?

14.1 Le signal NDVI : la chute

Avant la récolte, le NDVI passe progressivement de 0.7 (canopée verte mais commençant à sénescer) à 0.4 (plante sèche, encore debout) — c'est la **sénescence**.

Au moment de la récolte (passage de la moissonneuse), il y a une **cassure** brutale : de 0.4-0.5 (plante sèche debout) à 0.15-0.25 (sol nu avec un peu de paille). En **moins d'une semaine**, le NDVI baisse de 0.25-0.30 points.

Détection ML : la **chute brutale du NDVI sous 0.4** dans la période avril-juillet est un signal très fiable de récolte imminente (dans les 1-3 semaines).

14.2 Le signal SAR : la remontée du ratio VV/VH

En SAR, c'est l'inverse :

- **Avant récolte** : canopée dense → ratio VV/VH bas (~5-6 dB)
- **Pendant récolte** : la canopée disparaît, le sol nu et la paille restent
- **Après récolte** : ratio VV/VH remonte brutalement (~8-10 dB)

Le SAR permet donc de détecter la récolte **même en cas de couverture nuageuse** qui aurait masqué le NDVI. C'est une **redondance précieuse**.

14.3 Le signal météo : préparation

Au-delà du jour J de la récolte, les variables météo précédentes donnent des indices :

- **GDD cumulé** : si la culture a accumulé 2200°C·jours, elle est probablement mûre
- **Bilan hydrique négatif** : la sénescence s'accélère en cas de stress
- **Ensoleillement élevé en juin** : favorise une maturation rapide

14.4 La combinaison de tous les signaux

Aucun signal seul n'est parfait. Le modèle ML va apprendre à **combinaison** tous ces signaux pour faire une prédiction robuste :

Logique du modèle :

- NDVI a chuté sous 0.4 ? Probable récolte imminente.
- Mais le ratio VV/VH n'a pas encore remonté ? Attends quelques jours.
- Mais le GDD est encore bas (2050°C·j) ? La plante n'est pas physiologiquement mûre.
- Mais le sol a un AWC bas et il fait sec ? La maturation peut s'accélérer brutalement.

Notre modèle ML apprend automatiquement ces règles à partir des 1500 parcelles d'historique.

PARTIE V — L'approche Machine Learning

15. Pourquoi le Machine Learning ?

15.1 Limite des approches traditionnelles

Pour prédire la date de récolte, plusieurs approches existaient avant le ML :

Approche	Principe	Limite
Modèle agronomique mécaniste	Équations physiologiques (croissance, GDD, etc.)	Suppose une variété connue, ignore la diversité réelle
Observations terrain	Visite des parcelles, mesures manuelles	Coûteux, lent, à grande échelle impossible
Règles expert	"Si GDD > X et NDVI < Y alors récolte dans 2 semaines"	Trop rigide, n'apprend pas de l'historique

15.2 L'avantage du ML

Le Machine Learning **apprend automatiquement** à partir de données historiques. On lui donne :

- Des **exemples** (1500 parcelles × 5 ans, soit 1500 cas)
- Pour chaque exemple, des **features** (NDVI, SAR, météo, sol) — l'entrée du modèle
- Pour chaque exemple, la **vraie date** de récolte — la sortie attendue

Le modèle **apprend les patterns** qui relient features et date de récolte. Ensuite, donné de nouvelles features (par exemple celles de 2026), il prédit la date attendue.

Définition — Machine Learning (ML) : domaine de l'intelligence artificielle où un programme apprend à faire une tâche **à partir de données** plutôt qu'à partir de règles explicites programmées par un humain.

15.3 Les types de modèles qu'on va tester

Famille	Modèles	Force
Arbres de décision	Random Forest, XGBoost	Robuste, interprétable, baseline solide
Réseaux récurrents	LSTM, GRU	Excellent pour séries temporelles
Transformer	TFT (Temporal Fusion Transformer)	SOTA pour multi-features temporels
Multimodal custom	Architecture sur mesure	Combine vraiment les 6 sources

16. Les sources de données combinées

16.1 Récapitulatif des 6 sources

Source	Rôle	Type	Volume
Céré'Obs	Cible (dates récolte 50%)	1 valeur / année	5 valeurs
RPG	Identifiants parcelles	Static	1500 lignes

NASA POWER	Météo quotidienne	Time series	30 features × 1766 jours
SoilGrids	Sol (statique)	Static	39 features × 1500 parcelles
Sentinel-2	Indices végétation	Time series	15 features × ~118 fenêtres
Sentinel-1 SAR	Backscatter radar	Time series	3 features × ~100 scènes/parcelle

16.2 Pourquoi combiner ces 6 sources ?

Chacune apporte une **information unique** que les autres n'ont pas :

- **Céré'Obs** : la **vérité terrain** (sans elle, pas de prédiction possible)
- **RPG** : la **localisation** (sans elle, on ne sait pas quoi mesurer)
- **NASA POWER** : la **dynamique climatique** (sans elle, on ignore la chaleur accumulée)
- **SoilGrids** : le **contexte pédologique** (sans lui, on ignore pourquoi 2 parcelles voisines diffèrent)
- **Sentinel-2** : la **biophysique de la canopée** (sans lui, on ne voit pas l'état réel de la plante)
- **Sentinel-1** : la **structure** (sans lui, on n'a pas de signal en hiver)

16.3 La fusion : un défi technique

Combiner 6 sources avec des **granularités temporelles différentes** (statique vs quotidien vs hebdomadaire) est un défi :

- Le **sol** est statique (1 valeur par parcelle)
- La **météo** est quotidienne
- **Sentinel-2** est tous les 5 jours (mais avec trous nuages)
- **Sentinel-1** est tous les 6 jours (mais régulier)

Notre approche : agréger toutes les sources temporelles en **features dérivées** par (parcelle × année), pour produire un seul tableau "long" avec 1500 lignes et ~200 colonnes. Ce sera le **master dataset** que nous construirons à la prochaine étape.

17. Glossaire complet

Tous les termes techniques utilisés dans ce document et dans le projet, classés par thème.

Agronomie et phénologie

Terme	Définition
Anthèse	Période où les fleurs s'ouvrent ; synonyme de floraison. Stade BBCH 60-69.
BBCH	Échelle internationale (00-99) qui décrit les stades phénologiques. 92 = grain mûr.
Blé tendre	Espèce <i>Triticum aestivum</i> , utilisée pour pain, farine, pâtisserie.
Céré'Obs	Service public français de suivi des céréales (FranceAgriMer + Arvalis).
Épiaison	Sortie de l'épi hors de la dernière gaine foliaire (mai). BBCH 50-59.
Levée	Apparition des premières feuilles au-dessus du sol. BBCH 09-13.
Maturité physiologique	État où le grain a atteint sa taille et son poids définitifs (~40 jours après floraison).
Montaison	Allongement de la tige principale au printemps. BBCH 30-39.
Parcelle	Unité élémentaire d'exploitation agricole, homogène en culture et conduite.
Phénologie	Étude du calendrier des phénomènes naturels (germination, floraison, etc.).
Récolte 50%	Date à laquelle 50% des parcelles d'une région ont été récoltées.
RPG	Registre Parcellaire Graphique : base nationale française des parcelles agricoles.
Sénescence	Vieillessement de la plante : feuilles jaunissent, plante sèche.
Talle	Pousse latérale émergente de la base de la plante. Multiplie le nombre d'épis.
Tallage	Phase d'émergence des talles (déc-fév). BBCH 20-29.
Vernalisation	Besoin de froid hivernal pour déclencher la floraison (caractéristique du blé d'hiver).

Climat et météo

Terme	Définition
Bilan hydrique	Pluie – ET0. Positif : sol s'humidifie. Négatif : sol s'assèche.
ET0	Évapotranspiration de référence, "demande" en eau de l'atmosphère (mm/jour).
FAO-56	Méthode standard de calcul de l'ET0 (Penman-Monteith) publiée par la FAO.
GDD	Growing Degree Days. Mesure de chaleur accumulée : $(T_{max} + T_{min})/2 - T_{base}$.
NASA POWER	Service NASA fournissant des données météo globales à 0.5° de résolution.
Penman-Monteith	Formule complexe combinant T°, humidité, vent, rayonnement pour calculer ET0.
Rayonnement solaire	Énergie reçue du soleil par unité de surface (MJ/m²/jour).
Stress hydrique	État de la plante qui n'a pas assez d'eau pour ses besoins.

Sciences du sol

Terme	Définition
Argile	Particules < 0.002 mm. Retient bcp d'eau et nutriments, sol "lourd".
AWC	Available Water Capacity. Capacité de rétention en eau utile (mm/m).
Beauce	Plaine sédimentaire au nord-est de la CVL, premier terroir céréalier français.
CEC	Cation Exchange Capacity. Capacité du sol à retenir les nutriments.
Limon	Particules 0.002-0.05 mm. Texture idéale pour le blé (rétention modérée).
pH	Mesure de l'acidité du sol (0=acide, 7=neutre, 14=basique). Blé : 6-7.
Sable	Particules 0.05-2 mm. Drainage rapide, faible rétention.
SoilGrids	Base mondiale de données sol à 250 m, fournie par ISRIC.
SOC	Soil Organic Carbon. Carbone organique du sol = fertilité naturelle.
Texture	Proportions de sable, limon et argile dans le sol.

Télédétection

Terme	Définition
Bande spectrale	Intervalle de longueurs d'onde mesuré par un capteur (ex : Rouge = 620-680 nm).
Composite	Image agrégée sur une fenêtre temporelle (ex : médiane sur 15 jours).
Copernicus	Programme spatial européen d'observation de la Terre (ESA).
EVI	Enhanced Vegetation Index. Indice de végétation amélioré, 3 bandes.
GEE	Google Earth Engine. Plateforme cloud d'analyse géospatiale planétaire.
NDVI	Normalized Difference Vegetation Index. $(NIR-Red)/(NIR+Red)$. Verdeur.
NDWI	Normalized Difference Water Index. $(NIR-SWIR)/(NIR+SWIR)$. Hydratation.
NIR	Near InfraRed (proche infrarouge, 700-1300 nm). Massive réflexion par plantes saines.
Pixel	Plus petite unité d'une image satellite (10×10 m pour Sentinel-2).
Réflectance	Fraction de la lumière incidente réfléchie par une surface (entre 0 et 1).
SCL	Scene Classification Layer. Couche fournie par ESA qui identifie nuages, ombres...
Sentinel-1	Satellites radar SAR de Copernicus (S1A + S1B), bande C, depuis 2014.
Sentinel-2	Satellites optiques de Copernicus (S2A + S2B), 13 bandes, depuis 2015.
SWIR	Short-Wave InfraRed (1300-2500 nm). Sensible à l'eau dans la végétation.

Radar SAR

Terme	Définition
Bande C	Plage de fréquences micro-ondes (~5.4 GHz) utilisée par Sentinel-1.
DESCENDING	Orbite où le satellite descend du nord vers le sud (matin).

dB (décibel)	Unité logarithmique : $10 \times \log_{10}(\sigma^0)$. Valeurs négatives = peu de rétrodiffusion.
GRD	Ground Range Detected. Produit Sentinel-1 calibré et géoréférencé.
IW mode	Interferometric Wide. Mode d'acquisition standard sur les terres, 250 km de fauchée.
Polarisation	Orientation du champ électrique de l'onde radar (V=vertical, H=horizontal).
Rétrodiffusion (σ^0)	Fraction de l'énergie radar émise qui revient au satellite.
SAR	Synthetic Aperture Radar. Radar à synthèse d'ouverture (haute résolution).
Speckle	Bruit granulaire spécifique aux images SAR. Réduit par filtrage spatial.
VH	Émission Verticale, réception Horizontale (cross-polarisation).
VV	Émission Verticale, réception Verticale (co-polarisation).



Machine Learning

Terme	Définition
Feature	Variable d'entrée du modèle (ex : NDVI moyen avril, GDD cumulé, etc.).
Feature engineering	Création de nouvelles features à partir des données brutes (ex : peak_doy).
GRU	Gated Recurrent Unit. Réseau de neurones récurrent simplifié.
LSTM	Long Short-Term Memory. Réseau de neurones spécialisé pour séries temporelles.
Multimodal	Modèle qui combine plusieurs types/sources de données différents.
Random Forest	Algorithme à base d'arbres de décision multiples, agrégés par vote.
Target (cible)	Valeur que le modèle doit prédire (ici : DOY de récolte).
TFT	Temporal Fusion Transformer. Architecture SOTA pour séries temporelles.
Validation croisée	Méthode d'évaluation où on garde une partie des données pour tester.
XGBoost	Algorithme de boosting d'arbres très performant et populaire.

Conclusion

Si tu as lu jusqu'ici, bravo ! 🎉 Tu as maintenant tous les concepts nécessaires pour comprendre ce qui se passe dans ce projet de mémoire.

Récapitulatif des concepts clés

1. Le blé d'hiver est semé en octobre, traverse 7 stades phénologiques (codifiés BBCH 00-99), et est récolté en juillet au stade BBCH 92 — quand le grain est mûr et sec (12-15% d'humidité).

2. Le développement dépend du climat (température cumulée = GDD, bilan hydrique = Pluie-ET0) et du sol (texture, capacité de rétention en eau, fertilité).

3. Les satellites optiques (Sentinel-2) mesurent la verdure (NDVI), la vigueur (EVI) et l'hydratation (NDWI) de la canopée. Mais ils sont bloqués par les nuages en hiver.

4. Le radar SAR (Sentinel-1) mesure la structure et le volume de la canopée via la rétrodiffusion (σ^0) en deux polarisations (VV, VH). Il fonctionne **en tout temps**, comblant les trous hivernaux de l'optique.

5. Notre approche ML combine 6 sources de données (cible CéréObs, parcelles RPG, météo NASA POWER, sol SoilGrids, optique Sentinel-2, radar Sentinel-1) pour **apprendre** à prédire la date de récolte à partir des observations satellites et climatiques.

Ce qu'on va faire ensuite

Maintenant que la collecte de données est terminée, les prochaines étapes sont :

1. **Assembler le "master dataset"** : fusionner les 6 sources en un seul tableau prêt pour le ML
2. **Créer les features dérivées** : peak_doy, senescence_doy, GDD cumulé, etc.
3. **Entraîner les modèles** : RF, XGBoost, LSTM, Transformer, multimodal
4. **Évaluer et comparer** : quel modèle prédit le mieux ? Quelles features sont les plus importantes ?
5. **Construire un dashboard** : visualiser les prédictions, expliquer les résultats
6. **Rédiger le mémoire final** : avec tous les apprentissages

Et peut-être, à la fin, publier un **data paper** dans une revue scientifique, étant donné l'originalité de cette combinaison multi-source à l'échelle parcellaire en France.

Merci d'avoir lu ce document ! Tu es maintenant équipé pour comprendre le reste de la documentation du projet : le Master Data Dictionary (schéma complet de toutes les données) et le Master Dataset Report (méthodologie complète).