

Master Dataset Report

Méthodologie complète de bout-en-bout — Acquisition, validation, fusion

RAPPORT MÉTHODOLOGIQUE

Mémoire de Master

Prédiction de la fenêtre de récolte par Machine Learning

Blé d'hiver · Centre-Val de Loire · France

Université Indrashil — 2025

Encadrants : Dr. Vishvjit Thakar, Dr. Doreid Ammar

Version 1.0 — Document de référence méthodologique

Sommaire

PARTIE I — Contexte et motivation

1. Problème scientifique et applicatif
2. État de l'art en télédétection agricole
3. Originalité de notre approche

PARTIE II — Méthodologie globale

4. Schéma de bout-en-bout
5. Choix méthodologiques majeurs
6. Outils et plateformes

PARTIE III — Acquisition par source

7. Acquisition Céré'Obs (cible)
8. Acquisition RPG (parcelles)
9. Acquisition NASA POWER (météo)
10. Acquisition SoilGrids (sol)
11. Acquisition Sentinel-2 (optique)
12. Acquisition Sentinel-1 SAR (radar)

PARTIE IV — Apprentissages méthodologiques

13. Bugs identifiés et corrigés
14. Optimisations majeures
15. Décisions et compromis

PARTIE V — Validation et qualité

16. Validations effectuées
17. Indicateurs de qualité
18. Limitations connues

PARTIE VI — Prochaines étapes

19. Construction du master dataset
20. Approche ML prévue
21. Conclusion et perspectives

Public visé

Ce rapport méthodologique s'adresse à :

- 🧑‍🎓 **Le jury du mémoire** et les encadrants académiques
- 🧑‍💻 **Les futurs data scientists** qui continueront le projet
- 🧑‍🔬 **Les chercheurs** qui voudraient répliquer ou étendre la méthodologie
- 📊 **Les évaluateurs Kaggle** qui jugent la qualité scientifique du dataset
- 🎓 **Les étudiants** qui découvrent la télédétection agricole

Documents associés : ce rapport est conçu pour être lu après l'**Introduction Agronomique** (concepts) et en parallèle du **Master Data Dictionary** (schéma technique). Les trois documents forment la documentation complète du projet.

PARTIE I — Contexte et motivation

1. Problème scientifique et applicatif

1.1 La question de recherche

Question : Est-il possible de **prédire la date optimale de récolte du blé d'hiver** à l'échelle parcellaire, plusieurs jours à l'avance, en combinant des données satellites multi-sources (optique + radar), des données climatiques et des propriétés du sol, via des modèles de machine learning ?

1.2 L'enjeu agronomique

La récolte du blé est une étape **critique** du cycle agricole. Le moment exact de récolte influence :

- **La qualité du grain** : humidité, taux de protéines, force boulangère
- **Le rendement final** : pertes en cas de récolte tardive (égrenage, verse, germination sur pied)
- **Les coûts d'exploitation** : séchage (si grain trop humide), planification de la moissonneuse
- **La logistique** : silos, transport, transformation aval

Récolter **5 jours trop tôt** peut représenter une perte de qualité de 10-15 % et nécessiter un coût de séchage de 20-30 €/tonne. **5 jours trop tard**, en cas d'orage ou de canicule, peut détruire 20-40 % du rendement.

1.3 L'enjeu scientifique

Au-delà de l'enjeu agricole direct, le projet répond à plusieurs questions de recherche ouvertes :

1. **Quels signaux satellites sont les plus prédictifs** de la maturation ? Optique (NDVI) ? Radar (σ^0) ? Les deux combinés ?
2. **Quelle est la résolution temporelle minimale** pour une prédiction fiable ? 1 semaine ? 2 semaines ?
3. **Le sol et le climat suffisent-ils sans satellite**, ou les indices végétation apportent-ils une information critique ?
4. **Quelle architecture ML est la plus adaptée** ? Arbres de décision ? Réseaux récurrents ? Transformers ?
5. **Peut-on transférer le modèle** à d'autres régions ou d'autres cultures ?

1.4 L'enjeu sociétal

Au-delà des enjeux agricoles directs, ce type de projet contribue à :

- **L'adaptation au changement climatique** : suivre les modifications du calendrier agricole
- **La souveraineté alimentaire** : prévision des récoltes nationales
- **Le marché des matières premières** : transparence des prévisions
- **L'open data en recherche** : mise à disposition publique des données et méthodes

2. État de l'art en télédétection agricole

2.1 Évolution historique

Période	Approche dominante	Limites
Avant 2000	Observations terrain + satellites bas-résolution (NOAA AVHRR ~1km)	Résolution insuffisante pour le parcellaire
2000-2015	Landsat (30m), MODIS (250m) — modèles agronomiques	Revisite lente, dépendance aux nuages
2015-2020	Sentinel-2 (10m, 5 jours) — démocratisation du parcellaire	Toujours sensible aux nuages
2020+	Multi-source (S2 + S1) + ML/DL avancé	Encore peu d'études publiques en France

2.2 Travaux comparables

Plusieurs études récentes ont exploré la prédiction de stades phénologiques ou de récolte :

Étude	Zone	Approche	Limite
Vannoppen et al. (2022)	Belgique (Flandre)	S2 + LSTM pour phénologie	Pas de SAR, échelle régionale
Loberet et al. (2023)	Allemagne	S2 + S1 pour reconnaissance cultures	Classification, pas prédiction date
Selena Jasmine (2025)	Inde (riz)	S2 + EOS-06 SCAT-3 pour rendement	Échelle district, pas parcellaire
Belda et al. (2020)	Espagne	S2 pour suivi phénologique blé	Pas de prédiction date récolte

2.3 Gaps identifiés dans la littérature

À notre connaissance, aucune étude publique ne combine simultanément :

- Échelle **parcellaire** (pas régionale ou département)
- Combinaison **Sentinel-2 + Sentinel-1** à l'échelle parcelle
- Intégration **sol + météo + satellites** en multi-source
- Application au **blé d'hiver en France métropolitaine**
- Mise à disposition **publique** du jeu de données complet
- Cible de prédiction = **date de récolte** (et non rendement)

Cette combinaison fait l'originalité du présent projet de mémoire.

3. Originalité de notre approche

3.1 Trois innovations méthodologiques

Innovation 1 — Multi-source à l'échelle parcelle

La quasi-totalité des études existantes opèrent à l'échelle régionale ou départementale. Notre approche descend à la **parcelle agricole individuelle** (1500 parcelles), ce qui :

- Permet de capturer la **variabilité intra-régionale** (différents sols, micro-climats)
- Produit un signal d'entraînement plus riche (1500 observations vs ~6 régionales)
- Ouvre la voie à des applications opérationnelles parcellaires

Innovation 2 — Fusion S2 + S1 + sol + météo

Le projet intègre 4 modalités très différentes en information :

- **Optique (S2)** : photosynthèse, vigueur photosynthétique
- **Radar (S1)** : structure de la canopée, biomasse, indépendant des nuages
- **Sol (SoilGrids)** : capacité de rétention en eau, fertilité chimique
- **Météo (NASA POWER)** : températures, pluies, rayonnement, ET0

Cette quadruple intégration n'est pas courante dans la littérature publique.

Innovation 3 — Mise à disposition open data

Les 6 datasets raw sont déposés publiquement sur Kaggle sous licence CC BY 4.0. Cela permet :

- **Répliquabilité totale** de l'expérience
- **Réutilisation** par la communauté scientifique
- **Benchmarking** de futures méthodes
- **Valeur académique** (potentiel data paper)

3.2 Positionnement scientifique

Notre contribution : à notre connaissance, le projet produit le **premier dataset multi-source public à l'échelle parcellaire pour la prédiction de la date de récolte du blé d'hiver en France**. Ce caractère original ouvre des perspectives de publication (data paper) en parallèle des résultats de modélisation ML.

PARTIE II — Méthodologie globale

4. Schéma de bout-en-bout

4.1 Vue d'ensemble du pipeline

Le projet se décompose en **5 grandes phases** :




Figure 4.1 — Pipeline de bout-en-bout du projet : 5 phases distinctes. La présente version du rapport documente les phases 1 à 3 (terminées). Les phases 4 (assemblage) et 5 (ML) seront documentées dans une future version.

4.2 Statut actuel du projet

SOURCES ACQUISES	DATASETS KAGGLE	DOCUMENTS PDF	TOTAL VOLUME DONNÉES
6 / 6	6 / 6	19	~620 Mo

5. Choix méthodologiques majeurs

Au cours de la conception du projet, plusieurs décisions stratégiques ont été prises. Cette section les documente avec leur justification.

5.1 Décision : approche tabulaire (et non images)

Décision : agréger toutes les données satellites en **features tabulaires** (au lieu d'utiliser des images brutes).

Justification :

- Les CNN/ViT sur images satellites demandent des GPU coûteux et des volumes de données massifs
- L'approche tabulaire permet d'utiliser **tous les modèles ML** (RF, XGBoost, LSTM, Transformer)
- Les indices de végétation (NDVI, EVI, NDWI) condensent déjà l'information physique pertinente
- L'interprétabilité (SHAP, LIME) est plus directe sur des features tabulaires
- La taille de notre échantillon (1500) est plus adaptée aux modèles tabulaires

5.2 Décision : 5 années indépendantes (pas de séries temporelles inter-annuelles)

Décision : ré-échantillonner 300 nouvelles parcelles chaque année (au lieu de suivre les mêmes 300 parcelles sur 5 ans).

Justification :

- La rotation culturale en CVL fait que seulement **17,1 %** des parcelles portent du blé deux années consécutives
- Suivre les mêmes parcelles aurait drastiquement réduit la taille de l'échantillon
- Pour la prédiction de date de récolte, l'inter-annualité n'est pas essentielle (chaque saison est un cycle complet)
- Cette approche permet de capturer plus de diversité agronomique (différents sols, exploitants, pratiques)

5.3 Décision : Sentinel-1 + Sentinel-2 combinés (et non un seul)

Décision : intégrer aussi Sentinel-1 (radar) en plus de Sentinel-2 (optique).

Justification :

- Sentinel-2 perd ~26 % de couverture en hiver à cause des nuages
- Sentinel-1 fournit ~8 scènes par parcelle par mois **toute l'année**
- Le ratio VV/VH est un **marqueur direct de récolte** (remontée brutale post-moisson)
- La combinaison atteint ~18 scènes/parcelle/mois, idéal pour les modèles séquentiels (LSTM, Transformer)

5.4 Décision : 3 granularités temporelles (15j, 7j, brut)

Décision : exporter Sentinel-2 à 3 granularités temporelles différentes (composites 15 jours, 7 jours, et brut par scène).

Justification :

- Différentes architectures ML demandent différentes résolutions temporelles
- **15 jours** : ML classique (RF, XGBoost) — données dense, peu de NaN
- **7 jours** : modèles séquentiels (LSTM, GRU) — résolution plus fine
- **Brut** : Transformer + flexibilité totale en Python
- Évite de relancer Google Earth Engine pour chaque architecture testée

5.5 Décision : extraction WCS (et non REST API) pour SoilGrids

Décision : télécharger les rasters complets SoilGrids via WCS au lieu de l'API REST point-par-point.

Justification :

- API REST : ~5 heures pour 1500 parcelles
- WCS rasters : ~3,3 minutes (gain **91x plus rapide**)
- Permet aussi de visualiser et valider les rasters globalement
- Conserve la flexibilité d'extraire d'autres parcelles plus tard sans recharger

5.6 Décision : aucune donnée privée d'agriculteur

Décision : utiliser uniquement des données **publiques et observables depuis l'extérieur** (pas de variété cultivée, date de semis, fertilisation, etc.).

Justification :

- Reproductibilité : la méthode peut être appliquée à n'importe quelle parcelle sans consentement
- Éthique : pas d'accès à des données sensibles agriculteur

- Scalabilité : applicable à des millions de parcelles sans collecte terrain
- C'est aussi un défi méthodologique : peut-on prédire la récolte sans connaître la variété ?

6. Outils et plateformes

6.1 Environnement de développement

Outil	Version	Usage
Kaggle Notebooks	Cloud	Environnement principal d'exécution Python
Google Earth Engine	JavaScript API	Acquisition Sentinel-2 et Sentinel-1
Python	3.10+	Langage principal
Pandas	2.x	Manipulation tabulaire
GeoPandas	0.14+	Données géospatiales (RPG, parcelles)
Rasterio	1.3+	Lecture des rasters SoilGrids (WCS)
Requests	—	Téléchargement NASA POWER (API)
OpenPyXL	—	Lecture Excel Céré'Obs
Matplotlib / Seaborn	—	Visualisations EDA

6.2 Sources de données externes

Source	Plateforme d'accès	Type d'API
Céré'Obs	Fichier Excel public (FranceAgriMer)	Téléchargement direct
RPG	data.cquest.org (mirror)	Shapefiles par région
NASA POWER	power.larc.nasa.gov	REST API JSON
SoilGrids	maps.isric.org	WCS (Web Coverage Service)
Sentinel-2	Google Earth Engine	JavaScript API (GEE)
Sentinel-1	Google Earth Engine	JavaScript API (GEE)

6.3 Plateformes de dépôt

Plateforme	Usage	URL principale
Kaggle	Dépôt public des 6 datasets raw	kaggle.com/rgislikassi
Google Drive	Sorties brutes de Google Earth Engine	Folder "GEE_Wheat_Thesis"

6.4 Reproductibilité

Engagement de reproductibilité :

- Tous les datasets raw sont **publics** sur Kaggle (licence CC BY 4.0)
- Les scripts d'acquisition sont basés sur des **outils gratuits** (Kaggle, GEE, APIs publiques)
- Le **seed aléatoire** est fixé (random_state=42) pour le tirage RPG
- Les **versions logicielles** sont documentées dans les notebooks Kaggle
- Toute la **méthodologie est documentée** dans 19 PDFs publics

N'importe quel chercheur peut, en suivant ce rapport, reproduire l'intégralité du jeu de données.

PARTIE III — Acquisition par source

7. Acquisition CéréObs (cible)

Méthodologie d'extraction de la date de récolte 50% régionale

7.1 Identification de la source

La **fenêtre optimale de récolte** est l'information cible (target) du projet. Sans cette donnée de référence, aucun apprentissage supervisé n'est possible. Notre recherche a identifié plusieurs candidats potentiels :

Source candidate	Précision spatiale	Disponibilité publique	Verdict
CéréObs (FranceAgriMer)	Régionale	✓ Excel public	★ Choisi
Agreste (statistiques)	Départementale	✓ Tableaux	Trop tardif (post-récolte)
Sentinel-2 (détection)	Parcellaire	—	Tautologique (variable d'entrée)
Données agriculteurs	Parcellaire	✗ Privées	Inaccessible

7.2 Téléchargement du fichier source

Le fichier Excel de CéréObs est disponible sur le site de FranceAgriMer. Nom du fichier : `SCR-GRC-CERE0BS_CP_depuis_2015-A26.xlsx`.

Note : ce fichier Excel contient les données de toutes les céréales (blé tendre, blé dur, orge, etc.) pour toutes les régions françaises depuis 2015. C'est une mine d'or pour la recherche phénologique en France.

7.3 Extraction par interpolation linéaire

La **date de récolte 50%** n'est pas explicitement donnée. Le fichier fournit, semaine par semaine, le pourcentage de surface régionale récoltée. Notre extraction utilise une **interpolation linéaire** :

- Filtrage : CULTURE = "BTH" (Blé Tendre d'Hiver) ET REGION = "Centre-Val de Loire"
- Pour chaque année, on identifie les **deux semaines encadrant 50 %** :
 - Semaine N : SURFACE_RECOLTEE_PCT < 50 %
 - Semaine N+1 : SURFACE_RECOLTEE_PCT ≥ 50 %
- Interpolation linéaire entre les deux dates pour trouver le jour où on a atteint exactement 50 %
- Conversion en DOY (Day of Year)

7.4 Code Python de l'extraction

```
import pandas as pd

df = pd.read_excel('SCR-GRC-CERE0BS_CP_depuis_2015-A26.xlsx')
df = df[(df['CULTURE'] == 'BTH') & (df['REGION'] == 'Centre-Val de Loire')]

results = []
for year, group in df.groupby('CAMPAGNE'):
    group = group.sort_values('DATE_DEBUT_SEMAINE')
    # Trouver les deux semaines encadrant 50 %
    before = group[group['SURFACE_RECOLTEE_PCT'] < 50].iloc[-1]
    after = group[group['SURFACE_RECOLTEE_PCT'] >= 50].iloc[0]
    # Interpolation linéaire
    pct_diff = after['SURFACE_RECOLTEE_PCT'] - before['SURFACE_RECOLTEE_PCT']
    date_diff = (after['DATE_DEBUT_SEMAINE'] - before['DATE_DEBUT_SEMAINE']).days
    days_to_50 = (50 - before['SURFACE_RECOLTEE_PCT']) / pct_diff * date_diff
    harvest_date = before['DATE_DEBUT_SEMAINE'] + pd.Timedelta(days=days_to_50)
    results.append({
        'year': year,
        'harvest_date': harvest_date,
```

```
'harvest_doy': harvest_date.dayofyear
})

target = pd.DataFrame(results)
```

7.5 Résultats obtenus

Année	Récolte 50% (DOY)	Date calendaire	Particularités
2020	185	3 juillet 2020	Année moyenne, ensoleillement standard
2021	199	18 juillet 2021	Printemps frais ralentit maturation (+14j)
2022	183	2 juillet 2022	Canicule en mai accélère maturation (-2j)
2023	184	3 juillet 2023	Conditions moyennes
2024	195	13 juillet 2024	Printemps humide, retard (+10j)

La variabilité inter-annuelle est de **16 jours** entre 2022 (le plus précoce) et 2021 (le plus tardif). Cette variabilité est ce que notre modèle ML cherchera à expliquer.

7.6 Limites de la cible

Limite importante : la cible est **régionale**, pas **parcellaire**. Toutes les parcelles d'une même année reçoivent la même valeur de `harvest_doy`.

Conséquences :

- Notre modèle prédit la **date régionale moyenne**, pas la date individuelle
- Les features parcellaires (sol, S2, S1, météo) servent à expliquer les **années**, pas les parcelles individuelles
- Idéalement, on aurait des dates de récolte par parcelle, mais ces données ne sont pas publiques

Mitigation : on peut espérer qu'un modèle bien entraîné capturera des effets parcellaires en exploitant les corrélations features × cibles régionales. C'est une question de recherche en soi.

8. Acquisition RPG (parcelles)

Sélection aléatoire de 1500 parcelles de blé en CVL

8.1 Source : Registre Parcellaire Graphique

Le **RPG** est la base nationale française qui répertorie toutes les parcelles agricoles déclarées par les exploitants dans le cadre de la PAC. Il est publié annuellement par l'IGN et le Ministère de l'Agriculture.

Pour des raisons de licence, le RPG officiel n'est pas directement téléchargeable. Nous avons utilisé un **miroir public** : data.cquest.org, qui distribue les shapefiles par région et par année sous licence ouverte.

8.2 Téléchargement des shapefiles

Pour chaque année (2020-2024), nous avons téléchargé le shapefile RPG pour la région **Centre-Val de Loire**. Chaque shapefile contient ~80 000 à 90 000 parcelles de blé tendre :

Année	Parcelles BTH totales en CVL
2020	75 903
2021	89 171
2022	83 206
2023	80 346
2024	69 785

8.3 Stratégie d'échantillonnage

À partir de cette population annuelle, nous avons effectué un **échantillonnage aléatoire stratifié** :

1. Filtrage : `surf_parcel >= 1.0` hectare (élimination des micro-parcelles)
2. Tirage aléatoire : 300 parcelles par année
3. Seed : `random_state=42` (pour reproductibilité)
4. Calcul des centroïdes WGS84 (pour les requêtes API ultérieures)

8.4 Validation de l'indépendance temporelle

Une question importante : faut-il échantillonner les **mêmes 300 parcelles** chaque année (suivi temporel), ou **300 nouvelles** chaque année (échantillons indépendants) ?

Analyse menée : nous avons calculé le taux de **rotation culturale** en CVL. Sur 2 années consécutives, seulement **17,1 %** des parcelles portent du blé. C'est cohérent avec les pratiques agronomiques (rotation tous les 2-3 ans).

Conséquence : suivre les mêmes parcelles aurait drastiquement réduit notre échantillon (de 300 à ~50 en commun sur 5 ans). Nous avons donc choisi l'**échantillonnage indépendant annuel**, ce qui :

- Maximise la taille de l'échantillon ($300 \times 5 = 1500$)
- Capture plus de diversité agronomique (différents sols, exploitants)
- Évite les biais de continuité (les "bonnes" parcelles qui portent du blé chaque année peuvent ne pas être représentatives)

8.5 Schéma final

Le fichier final `parcelles_ble_cvl_sample.csv` contient 1500 lignes avec les colonnes suivantes :

Colonne	Source	Exemple
<code>parcelle_uid</code>	Construit (<code>year_idparcel</code>)	2020_4771311
<code>year</code>	Construit	2020

id_parcel	RPG original	4771311
code_cultu	RPG	BTH
surf_parc	RPG (m²) → ha	5.2
departement	Code INSEE	28
commune	Code INSEE	28085
latitude, longitude	Centroïde WGS84	48.4523, 1.4912

8.6 Validation visuelle

Contrôle effectué : nous avons généré une carte des 1500 parcelles et vérifié visuellement qu'elles se répartissent bien sur les 6 départements de CVL, avec une densité conforme à la réalité agricole (plus dense en Beauce, moins dense en Sologne et Boischaud).

9. Acquisition NASA POWER (météo)

Téléchargement quotidien des variables climatiques pour 6 points CVL

9.1 Choix du service NASA POWER

Plusieurs sources météo étaient candidates :

Source	Résolution spatiale	Accès	Verdict
Météo-France OpenData	Stations terrain (~5 km)	API limitée	Couverture variable, complications API
ECMWF ERA5	0.25° (~28 km)	Climate Data Store	Excellent mais complexe à intégrer
NASA POWER	0.5° (~55 km)	REST API simple	★ Choisi (simplicité + suffisant)
ECMWF MARS	Très fin	Académique	Pas open data

9.2 Points d'extraction

NASA POWER fournit des données pour n'importe quel point lat/lon. Pour notre projet, on extrait **6 points** correspondant aux préfectures des 6 départements de CVL :

Département	Préfecture	Latitude	Longitude
28	Chartres	48.45°N	1.49°E
45	Orléans	47.90°N	1.91°E
41	Blois	47.59°N	1.33°E
37	Tours	47.39°N	0.69°E
18	Bourges	47.08°N	2.40°E
36	Châteauroux	46.81°N	1.69°E

Chaque parcelle se voit associée à la météo de son chef-lieu départemental (jointure par `departement`). Ce niveau de granularité est cohérent avec la résolution native de NASA POWER (0.5° = ~55 km).

9.3 Période et variables téléchargées

- **Période** : 2019-10-01 → 2024-07-31 (1 766 jours)
- **Variables brutes** : 8 (T2M, T2M_MIN, T2M_MAX, PRECTOTCORR, RH2M, WS2M, ALLSKY_SFC_SW_DWN, PS)
- **Format de retour** : JSON via REST API

9.4 Variables dérivées calculées

À partir des 8 variables brutes, nous avons calculé **22 indicateurs agronomiques** (détaillés dans le Data Dictionary, Section 7.4). Les plus importants sont :

Catégorie	Variables clés	Intérêt agronomique
Degrés-jours	gdd_base0_cumul, gdd_base5_cumul	Indicateur de maturation cumulée
Évapotranspiration	et0, et0_cumul	Demande hydrique de l'atmosphère
Bilan hydrique	bilan_hydrique, bilan_hydrique_cumul	Stress hydrique cumulé
Stress thermique	jours_chauds, amplitude_therm	Risque canicule, échaudage
Cumuls saisonniers	pluie_30j, rayonnement_cumul	Disponibilité ressources

9.5 Bug critique identifié et corrigé : ET0

Bug initial : dans la première version du pipeline, nous avons appliqué par erreur une conversion $\times 3.6$ à la variable ALLSKY_SFC_SW_DWN avant de calculer ET0, en supposant qu'elle était fournie en Wh/m². En réalité, NASA POWER fournit cette variable déjà en MJ/m²/jour.

Conséquence du bug : les valeurs ET0 calculées étaient artificiellement multipliées par ~3.6, donnant des ET0 irréalistes (15-20 mm/jour au lieu de 4-6 mm/jour typiques).

Correction : nous avons retiré la conversion incorrecte. La version actuelle utilise les valeurs natives de NASA POWER sans transformation.

Validation post-correction : ET0 moyen sur juin-juillet ≈ 4.5 mm/jour, conforme aux valeurs de référence FAO pour la France métropolitaine.

9.6 Validation des valeurs obtenues

Nous avons validé les valeurs en les comparant à des références agronomiques de la CVL :

Variable	Valeur observée (moyenne)	Référence agronomique	Verdict
T_moyenne annuelle	11,5 °C	~11 °C (Météo-France)	✓
Pluviométrie annuelle	650 mm	600-700 mm (CVL)	✓
ET0 annuel	1 000 mm	950-1 050 mm (FAO)	✓
GDD base 0 cumul à juin	1 800-2 200 °C·j	~2 000 °C·j	✓
Pluie cumul oct-juil	520 mm	500-600 mm	✓

10. Acquisition SoilGrids (sol)

Extraction de 39 features via WCS rasters (optimisation 91×)

10.1 Choix de SoilGrids

Plusieurs sources de données sol étaient candidates :

Source	Résolution	Couverture	Verdict
BDAT (INRAE France)	Très précis mais ponctuel	Échantillons terrain	Pas de couverture continue
RMQS (INRAE)	Excellent	~2 000 sites en France	Trop ponctuel pour 1500 parcelles
SoilGrids	250 m, prédictif ML	Mondiale	★ Choisi (couverture + résolution)
European Soil Data Centre	1 km	Europe	Moins précis que SoilGrids

10.2 Première tentative : API REST

SoilGrids fournit une API REST qui permet d'extraire les valeurs en un point lat/lon donné. Première approche tentée :

```
# Pseudo-code de l'approche initiale (REST API)
for parcelle in 1500_parcelles:
    for property in 13_properties:
        for depth in 3_depths:
            url = f"https://rest.isric.org/soilgrids/v2.0/properties/query?"
            url += f"lon={parcelle.lon}&lat={parcelle.lat}&property={property}"
            url += f"&depth={depth}"
            response = requests.get(url)
            # Stocker la valeur

# Estimation : 1500 × 13 × 3 = 58 500 requêtes
# Temps estimé (rate-limited) : ~5 heures
```

10.3 Optimisation : extraction par WCS rasters

Innovation méthodologique : au lieu de 58 500 requêtes API individuelles, on télécharge **39 rasters complets** (Web Coverage Service) couvrant toute la CVL, puis on échantillonne localement les 1500 points.

```
# Approche WCS optimisée
import rasterio
from owslib.wcs import WebCoverageService

wcs = WebCoverageService('https://maps.isric.org/mapserv?map=/map/SoilGrids')
for property in 13_properties:
    for depth in 3_depths:
        # Télécharger 1 raster pour la zone CVL
        raster = wcs.getCoverage(
            identifier=f"{property}_{depth}_mean",
            bbox=cvl_bounds, crs='EPSG:4326', format='GEOTIFF'
        )
        # Échantillonner les 1500 points localement
        with rasterio.open(raster) as src:
            for parcelle in 1500_parcelles:
                values[parcelle.uid] = src.sample([(parcelle.lon, parcelle.lat)])

# 39 téléchargements × ~3 secondes + échantillonnage local
# Temps mesuré : 3,3 minutes (vs 5 heures REST API)
# Gain : 91× plus rapide
```


10.4 Gestion des valeurs manquantes

Sur 1500 parcelles, **2 (0,13 %)** présentaient des valeurs NoData pour certaines propriétés, dues à des artefacts du raster SoilGrids près des frontières administratives.

Nous avons appliqué une **imputation par plus proche voisin** :

- 1. Identifier les parcelles avec NoData
- 2. Trouver la parcelle voisine (en distance euclidienne) avec valeur valide
- 3. Copier la valeur du voisin

Justification agronomique : les propriétés du sol varient peu sur des distances courtes (quelques centaines de mètres). La distance moyenne au plus proche voisin était de **0,22 km** (= 1 pixel SoilGrids), donc l'imputation est physiquement raisonnable.

10.5 Validation des valeurs

Propriété	Médiane CVL observée	Référence INRAE	Verdict
Argile (g/kg, 0-30 cm)	185	150-200 (CVL)	✓
Limon (g/kg)	420	400-500 (Beauce)	✓
Sable (g/kg)	395	300-450	✓
pH eau	6.7	6.5-7.0 (typique blé)	✓
SOC (dg/kg)	148	100-200	✓
CEC (cmol+/kg)	15.2	10-25	✓

Toutes les médianes observées tombent dans les plages de référence INRAE pour la CVL, ce qui valide la qualité de l'extraction SoilGrids.

11. Acquisition Sentinel-2 (optique)

3 granularités temporelles · 1500 parcelles · 5 ans

11.1 Choix de la plateforme : Google Earth Engine

Pour Sentinel-2, plusieurs plateformes d'accès étaient candidates :

Plateforme	Avantages	Inconvénients	Verdict
Copernicus Hub	Source officielle ESA	Téléchargements GB, traitement local complexe	Inadapté pour 1500 parcelles
SentinelHub	API ergonomique	Payant au-delà d'un quota	Coût rédhibitoire
Google Earth Engine	Cloud computing gratuit, COPERNICUS/S2_SR_HARMONIZED prêt	JavaScript API spécifique	★ Choisi
AWS Open Data	S2 brut accessible	Pas de pré-traitement, complexité	Trop bas niveau

11.2 Téléchargement de l'asset des parcelles vers GEE

Première étape : uploader notre échantillon de 1500 parcelles comme **asset** dans GEE pour pouvoir l'utiliser dans les scripts JavaScript :

1. Conversion du fichier `parcelles_ble_cv1_sample.geojson` en format shapefile compatible GEE
2. Upload manuel dans la console GEE : `projects/gen-lang-client-0405586640/assets/parcelles_ble_cv1_sample`
3. Vérification : 1500 features avec attributs (parcelle_uid, year, departement, etc.)

11.3 Pipeline GEE — composites 15 jours

Le pipeline JavaScript pour produire les composites 15 jours se résume ainsi :

```
var parcelles = ee.FeatureCollection(
  'projects/gen-lang-client-0405586640/assets/parcelles_ble_cv1_sample'
);

// Charger la collection harmonisée
var s2 = ee.ImageCollection('COPERNICUS/S2_SR_HARMONIZED')
  .filterDate('2019-10-01', '2024-07-31')
  .filterBounds(parcelles)
  .filter(ee.Filter.lt('CLOUDY_PIXEL_PERCENTAGE', 60));

// Masquage des nuages via SCL (Scene Classification Layer)
function maskClouds(image) {
  var scl = image.select('SCL');
  var mask = scl.neq(3).and(scl.neq(7)).and(scl.neq(8))
    .and(scl.neq(9)).and(scl.neq(10)).and(scl.neq(11));
  return image.updateMask(mask);
}

// Calculer NDVI, EVI, NDWI
function computeIndices(image) {
  var ndvi = image.normalizedDifference(['B8', 'B4']).rename('NDVI');
  var ndwi = image.normalizedDifference(['B8', 'B11']).rename('NDWI');
  var evi = image.expression(
    '2.5 * (NIR - RED) / (NIR + 6 * RED - 7.5 * BLUE + 1)', {
    'NIR': image.select('B8').divide(10000),
    'RED': image.select('B4').divide(10000),
    'BLUE': image.select('B2').divide(10000)
  }).rename('EVI');
  return image.addBands([ndvi, evi, ndwi]);
}

// Composites 15 jours sur la fenêtre 2019-10 → 2024-07
var windowStart = ee.Date('2019-10-01');
var nWindows = 118; // 118 fenêtres de 15 jours
var windows = ee.List.sequence(0, nWindows - 1).map(function(i) {
```

```

var start = windowStart.advance(ee.Number(i).multiply(15), 'day');
var end = start.advance(15, 'day');
var subset = s2.filterDate(start, end).map(maskClouds).map(computeIndices);

// Empty window check
var count = subset.size();
var composite = ee.Algorithms.If(
  count.gt(0),
  subset.select(['NDVI', 'EVI', 'NDWI']).reduce(
    ee.Reducer.median().combine(ee.Reducer.mean(), '', true)
      .combine(ee.Reducer.minMax(), '', true)
      .combine(ee.Reducer.stdDev(), '', true)
  ).set({'window_start': start, 'n_images': count}),
  null
);
return composite;
});

// reduceRegions par parcelle, export CSV
var results = windows.filter(ee.Filter.notNull(['window_start']))
  .map(function(image) {
    return ee.Image(image).reduceRegions({
      collection: parcelles,
      reducer: ee.Reducer.mean(),
      scale: 20
    });
  });

Export.table.toDrive({
  collection: ee.FeatureCollection(results).flatten(),
  description: 's2_composites_15days_cv1',
  fileFormat: 'CSV'
});

```

11.4 Gestion des fenêtres vides (bug critique évité)

Problème rencontré : sur certaines fenêtres de 15 jours, aucune scène Sentinel-2 valide n'est disponible (hiver très nuageux, satellite en maintenance, etc.). Sans précaution, GEE plante avec une erreur "Empty collection".

Solution implémentée : utilisation de `ee.Algorithms.If(count.gt(0), ..., null)` pour gérer dynamiquement le cas où la collection est vide. Les fenêtres vides retournent `null` et sont filtrées par `ee.Filter.notNull(['window_start'])`.

Résultat : le pipeline ne plante jamais, même en présence de gros trous de couverture.

11.5 Les 3 granularités produites

Le même pipeline est exécuté 3 fois avec des paramètres différents pour produire **3 fichiers** :

Granularité	Fichier	Volume	Usage prévu
15 jours	s2_composites_15days_cv1.csv	~42 Mo, 177k lignes	ML classique (RF, XGBoost)
7 jours	s2_composites_7days_cv1.csv	~85 Mo, ~380k lignes	Modèles séquentiels (LSTM, GRU)
Brut par scène (5 fichiers/an)	sentinel2_raw_{2020-2024}.csv	~40 Mo × 5 = 200 Mo	Transformer, flexibilité maximale

11.6 Validation des données obtenues

Distribution NDVI saisonnière

Pour valider la qualité, nous avons analysé la distribution du NDVI mois par mois :

Mois	NDVI médian observé	NDVI attendu (blé)	Verdict
Novembre (levée)	0.32	0.30-0.40	✓
Février (tallage)	0.41	0.40-0.50	✓

Avril (montaison)	0.68	0.60-0.75	✓
Mai (épiaison/pic)	0.84	0.80-0.90	✓
Juin (maturation)	0.58	0.50-0.70	✓
Juillet (post-récolte)	0.22	0.15-0.30	✓

Pic NDVI selon les années

Année	Pic NDVI (DOY)	Date calendaire	Cohérence avec récolte (DOY)
2020	134	13 mai	Récolte 185 → 51 j après pic ✓
2021	143	23 mai	Récolte 199 → 56 j après pic ✓
2022	123	3 mai	Récolte 183 → 60 j après pic ✓
2023	118	28 avril	Récolte 184 → 66 j après pic ⚠
2024	128	7 mai	Récolte 195 → 67 j après pic ⚠

Apprentissage : l'écart pic NDVI → récolte varie entre 51 et 67 jours selon les années. C'est cohérent avec le fait que la phase pic → récolte dépend fortement de la température (été chaud accélère, été frais ralentit). Cet écart variable est précisément l'information que notre modèle ML cherchera à exploiter.

11.7 Limites identifiées

Limites de Sentinel-2 dans notre projet :

- **Couverture hivernale dégradée** : 50-70 % de scènes invalides en décembre-février à cause des nuages
- **Outliers EVI** : 0,12 % des mesures EVI sont aberrantes (à filtrer)
- **NDVI ↔ NDWI très corrélés** ($r = 0,93$), ce qui crée de la multicolinéarité pour certains modèles
- **Effet bord** sur petites parcelles : moyenne sur la parcelle inclut quelques pixels périphériques mixtes

12. Acquisition Sentinel-1 SAR (radar)

Backscatter VV/VH tout-temps · 5 fichiers annuels

12.1 Motivation d'inclure Sentinel-1

L'ajout de Sentinel-1 SAR à Sentinel-2 répond à plusieurs limites de l'optique :

Limite S2	Solution S1
50-70 % nuages en hiver	SAR traverse les nuages → ~8 scènes/mois en hiver aussi
Mesure réflectance (passif)	Mesure structure 3D (actif)
Saturation NDVI à 0.85+	Pas de saturation, sensible à la biomasse jusqu'à récolte
Signal récolte = chute NDVI	Signal récolte = remontée brutale ratio VV/VH

12.2 Configuration choisie

Plusieurs paramètres de configuration étaient possibles. Notre choix :

Paramètre	Choix	Justification
Collection	COPERNICUS/S1_GRD	Ground Range Detected, calibré en dB
Mode	IW (Interferometric Wide)	Standard pour observation terrestre, 250 km de fauchée
Polarisations	VV + VH	Polarisations transmises sur terre
Orbit pass	DESCENDING uniquement	Géométrie cohérente, angle d'incidence stable
Résolution finale	30 m	Suréchantillonnage depuis 10m, suffisant pour parcellaire
Filtre speckle	focal_median 50 m	Réduit le bruit granulaire du SAR

Pourquoi DESCENDING seulement ? En combinant ASCENDING et DESCENDING, on obtient plus de scènes mais avec des géométries différentes (angles d'incidence ~30° vs ~40°), ce qui crée des discontinuités dans la série temporelle. En limitant à DESCENDING, on perd ~50 % des scènes disponibles mais on gagne en cohérence radiométrique.

12.3 Pipeline GEE — backscatter VV/VH

```
var parcelles = ee.FeatureCollection(
  'projects/gen-lang-client-0405586640/assets/parcelles_ble_cv1_sample'
);

// Charger la collection
var s1 = ee.ImageCollection('COPERNICUS/S1_GRD')
  .filterDate('2019-10-01', '2024-07-31')
  .filterBounds(parcelles)
  .filter(ee.Filter.eq('instrumentMode', 'IW'))
  .filter(ee.Filter.eq('orbitProperties_pass', 'DESCENDING'))
  .filter(ee.Filter.listContains('transmitterReceiverPolarisation', 'VV'))
  .filter(ee.Filter.listContains('transmitterReceiverPolarisation', 'VH'));

// Filtre speckle + ratio VV/VH
function processImage(image) {
  // Filtre speckle médian local 50m
  var vv = image.select('VV').focal_median(50, 'circle', 'meters');
  var vh = image.select('VH').focal_median(50, 'circle', 'meters');

  // Ratio VV/VH en dB (différence en log = ratio)
  var ratio = vv.subtract(vh).rename('VV_VH_ratio');

  return image.addBands([
```

```
vv.rename('VV_filtered'),
vh.rename('VH_filtered'),
ratio
}).set('system:time_start', image.get('system:time_start'));
}

var processed = s1.map(processImage);

// Pour chaque scène, extraire les moyennes par parcelle
var scenesToFeatures = processed.map(function(image) {
  return image.reduceRegions({
    collection: parcelles,
    reducer: ee.Reducer.mean(),
    scale: 30
  }).map(function(f) {
    return f.set('scene_date', ee.Date(image.get('system:time_start'))
      .format('YYYY-MM-dd'));
  });
});

// Export par année
[2020, 2021, 2022, 2023, 2024].forEach(function(year) {
  var yearStart = ee.Date.fromYMD(year - 1, 10, 1);
  var yearEnd = ee.Date.fromYMD(year, 7, 31);
  var yearScenes = processed.filterDate(yearStart, yearEnd);
  // ... export to drive
});
```

12.4 Structure de l'export

Le pipeline produit 5 fichiers (un par saison agricole) :

Fichier	Période couverte	Taille approximative
sentinel1_sar_raw_2020.csv	2019-10-01 → 2020-07-31	~25 Mo
sentinel1_sar_raw_2021.csv	2020-10-01 → 2021-07-31	~25 Mo
sentinel1_sar_raw_2022.csv	2021-10-01 → 2022-07-31	~25 Mo
sentinel1_sar_raw_2023.csv	2022-10-01 → 2023-07-31	~25 Mo
sentinel1_sar_raw_2024.csv	2023-10-01 → 2024-07-31	~25 Mo

12.5 Validation et signature phénologique

Pour valider la qualité des données SAR, nous avons analysé la signature phénologique sur la saison 2020 :

Période	VV médian (dB)	VH médian (dB)	Ratio (dB)	Stade phénologique
Oct 2019	-9.2	-17.2	8.0	Semis (sol nu rugueux)
Nov-Déc	-8.9	-17.5	8.6	Levée (faible canopée)
Jan-Fév 2020	-9.0	-18.1	9.1	Tallage (croissance lente)
Mars	-10.7	-18.3	7.6	Montaison débute
Avr-Mai	-13.5	-19.1	5.6	Épiaison/floraison (canopée max)
Juin	-12.3	-18.7	6.4	Maturation (sénescence)
Juil (post-récolte)	-9.8	-17.6	7.8	Récolte → remontée

Signature phénologique parfaite : les valeurs VV diminuent de -9 dB (sol nu) à -13.5 dB (pic canopée) puis remontent à -9.8 dB (post-récolte). Cette signature en "U inversé" est la référence agronomique attendue pour le blé. **Le SAR fonctionne comme prévu.**

12.6 Statistiques de couverture

SCÈNES VALIDES / PARCELLE (MÉDIANE)	SCÈNES MAX / PARCELLE	DENSITÉ S1 / MOIS	VS SENTINEL-2
100	124	~8	2,4×

12.7 Complémentarité S1+S2 mesurée

Le bénéfice principal du SAR est de combler les trous nuageux de Sentinel-2. Nous avons mesuré cette complémentarité :

Mois	S2 scènes/parc	S1 scènes/parc	Total combiné
Décembre	2,6	8,0	10,6
Janvier	5,2	8,0	13,2
Février	2,4	8,0	10,4
Mars	4,2	8,0	12,2
Avril	8,0	8,0	16,0
Mai	9,6	8,0	17,6
Juin	10,2	8,0	18,2
Juillet	10,8	8,0	18,8
Moyenne	6,6	8,0	14,6

La densité combinée S1+S2 atteint **~15 scènes/parcelle/mois en moyenne**, dont une bonne partie en hiver (où S2 seul ne fournissait que 2-5 scènes). Cette combinaison fait de notre dataset l'un des plus denses publiquement disponibles pour le suivi du blé.

PARTIE IV — Apprentissages méthodologiques

Cette partie capitalise les apprentissages techniques et méthodologiques issus de plusieurs mois de travail. Elle vise à servir de **retour d'expérience** pour de futurs étudiants ou chercheurs travaillant sur des projets similaires.

13. Bugs identifiés et corrigés

13.1 Bug n°1 — Conversion erronée du rayonnement (ET0)

Symptôme : les valeurs ET0 calculées par notre pipeline NASA POWER étaient anormalement élevées (15-20 mm/jour en été), contre 4-6 mm/jour attendus.

Cause racine : nous avons appliqué une conversion $\times 3.6$ à la variable ALLSKY_SFC_SW_DWN, en supposant qu'elle était fournie en Wh/m² (auquel cas la conversion en MJ/m²/jour serait nécessaire). En réalité, NASA POWER livre cette variable directement en **MJ/m²/jour**.

Conséquence : l'ET0 quotidien était multiplié par ~3.6, et les cumuls saisonniers totalement irréalistes.

Correction : suppression de la conversion incorrecte. Validation post-correction par comparaison aux références FAO.

Leçon retenue : *toujours vérifier les unités natives des APIs externes avant de manipuler les variables, même si la documentation semble claire.* Pour le futur, ajout d'une phase systématique de "validation des unités" dans tous les pipelines.

13.2 Bug n°2 — Plantage GEE sur fenêtres temporelles vides

Symptôme : le pipeline Sentinel-2 plantait lors du traitement de certaines fenêtres de 15 jours, sans message d'erreur explicite, dans la console Google Earth Engine.

Cause racine : certaines fenêtres ne contenaient aucune scène Sentinel-2 valide (hiver très nuageux, maintenance satellite). L'appel à `imageCollection.reduce(...)` sur une collection vide générait une erreur fatale.

Correction : implémentation d'une vérification dynamique avec `ee.Algorithms.If(count.gt(0), composite, null)`, puis filtrage des nulls en aval.

Leçon retenue : *les pipelines distribués (cloud) ne tolèrent pas les cas dégénérés. Il faut toujours coder défensivement, surtout sur des sources temporelles longues où les trous sont inévitables.*

13.3 Bug n°3 — Valeurs NoData SoilGrids non détectées

Symptôme : certaines parcelles avaient des valeurs aberrantes pour le sol (pH = 0, argile = 0).

Cause racine : SoilGrids encode les valeurs NoData différemment selon la propriété (parfois 0, parfois -32768, parfois NaN). Notre première lecture rasterio ne reconnaissait pas tous les cas.

Correction :

1. Lecture explicite de l'attribut `nodata` de chaque raster
2. Conversion systématique en NaN avant tout calcul
3. Imputation par plus proche voisin pour les 2 parcelles concernées

Leçon retenue : *les conventions NoData varient entre sources et entre propriétés. Il faut toujours vérifier explicitement (et pas faire confiance aux valeurs apparentes).*

13.4 Bug n°4 — Effets de bord en composites 7 jours

Symptôme : les composites 7 jours montraient parfois des "creux" anormaux en milieu de saison, alors que les composites 15 jours sur la même période étaient propres.

Cause racine : une fenêtre 7 jours peut tomber sur 0 ou 1 scène valide (alors qu'une fenêtre 15 jours en a 2-3). Quand il n'y a qu'une seule scène, et qu'elle est partiellement nuageuse, le NDVI extrait est biaisé par les pixels masqués.

Correction : documentation de cette limitation. Pour les modèles séquentiels (LSTM, Transformer) utilisant les composites 7 jours, recommander un filtrage post-hoc `n_images >= 2` en pré-traitement.

Leçon retenue : *plus la granularité est fine, plus la sensibilité au bruit augmente. Il faut documenter ces compromis pour les utilisateurs aval.*

13.5 Synthèse des bugs

Bug	Source	Sévérité	Statut
Conversion ET0 ×3.6	NASA POWER	Critique	✓ Corrigé
Plantage fenêtres vides	Sentinel-2 GEE	Critique	✓ Corrigé
NoData SoilGrids	SoilGrids	Moyenne	✓ Corrigé (imputation)
Bruit composites 7j	Sentinel-2	Faible	📝 Documenté

14. Optimisations majeures

14.1 Optimisation n°1 — SoilGrids via WCS (91× plus rapide)

Problème initial : l'API REST de SoilGrids permettait d'extraire les 39 propriétés (13×3 profondeurs) point par point. Pour 1500 parcelles, cela représentait 58 500 requêtes API, soit ~5 heures de téléchargement (rate-limited).

Solution implémentée : télécharger les 39 rasters complets via WCS pour la zone CVL, puis échantillonner localement les 1500 points avec rasterio.

Gain mesuré : 3,3 minutes (vs 5 heures), soit un facteur **91× plus rapide**.

Bonus : les rasters téléchargés peuvent être réutilisés pour extraire des parcelles supplémentaires sans nouveau téléchargement.

Leçon retenue : face à une API REST avec rate-limiting, toujours évaluer s'il existe une alternative bulk (WCS, FTP, dump). Le gain peut être colossal.

14.2 Optimisation n°2 — Composites GEE plutôt que scènes brutes

Problème initial : exporter chaque scène Sentinel-2 individuellement aurait produit ~1700 lignes par parcelle $\times$ 1500 parcelles = 2,5 millions de lignes par année, soit ~200 Mo $\times$ 5 ans = 1 Go. La taille rendait la manipulation aval (Pandas) lente.

Solution implémentée : produire des composites 15 jours et 7 jours **dans GEE**, avant l'export. Cela réduit le volume tout en conservant l'information temporelle pertinente pour le ML classique.

Gain mesuré : 42 Mo (composites 15j) vs 200 Mo (raw), soit **5× plus léger**, sans perte d'information utile pour les modèles tabulaires.

Compromis assumé : on a gardé aussi le raw (5 fichiers de 40 Mo) pour les architectures nécessitant la résolution temporelle maximale (Transformer).

Leçon retenue : l'agrégation peut se faire à différents niveaux du pipeline (en amont dans GEE, en aval dans Pandas). Faire en amont quand on connaît bien l'usage final permet d'économiser bande passante et temps de traitement.

14.3 Optimisation n°3 — Filtre de qualité au niveau de la collection

Problème initial : sans pré-filtrage, GEE traite des milliers de scènes par fenêtre, dont beaucoup sont quasi-totalement nuageuses.

Solution implémentée : appliquer un filtre `CLOUDY_PIXEL_PERCENTAGE < 60 %` dès l'étape `filterMetadata`, avant tout calcul.

Gain mesuré : ~30 % de scènes en moins à traiter, donc 30 % de temps en moins. Le seuil 60 % est un compromis : plus restrictif (40 %) on perd des fenêtres entières en hiver ; plus permissif (80 %) on garde des scènes inutilisables.

Leçon retenue : filtrer le plus tôt possible dans le pipeline. Les "computations lazy" de GEE permettent ce filtrage gratuitement.

14.4 Optimisation n°4 — Documentation parallèle aux datasets

Problème initial : au début du projet, la documentation se faisait "à la fin", ce qui créait des oublis (variables non documentées, méthodes oubliées).

Solution implémentée : dès qu'un dataset est finalisé, produire **simultanément** un Data Dictionary et un Dataset Report PDF. Chaque dépôt Kaggle est donc accompagné d'une documentation immédiate.

Gain : documentation toujours à jour, pas de re-travail à la fin du projet, gain de temps estimé à 1-2 jours sur l'ensemble du mémoire.

Leçon retenue : *"document as you go" — la documentation au fil de l'eau est moins coûteuse qu'une documentation finale rétroactive.*

15. Décisions et compromis

Au-delà des bugs et optimisations, plusieurs **décisions méthodologiques** ont été prises qui méritent d'être explicitées avec leurs compromis.

15.1 Sélection régionale vs nationale

Option	Avantages	Inconvénients
1 région (CVL) — retenu	Pipeline manageable, climat homogène	Généralisation à d'autres régions à vérifier
3 régions	Plus de diversité climatique	3× plus de volume de données, complexité accrue
France entière	Modèle plus généralisable	Pipeline GEE massif, gestion des cas particuliers (Méditerranée, montagne)

Le choix d'une seule région (CVL) est un compromis entre **faisabilité dans le cadre d'un mémoire de master** et **diversité agronomique suffisante**. La méthodologie est conçue pour être **scalable** : on peut étendre à d'autres régions en relançant le pipeline.

15.2 Taille de l'échantillon (1500 parcelles)

Échantillon	Avantages	Inconvénients
500 parcelles	Pipeline rapide (1-2h GEE)	Peu de power statistique
1500 (300/an × 5) — retenu	Compromis vitesse/diversité, ML tabulaire viable	Peu pour deep learning massif
10 000 parcelles	Idéal pour DL	Pipeline GEE de plusieurs jours, quotas Drive

1500 parcelles est suffisant pour entraîner des modèles tabulaires (RF, XGBoost) avec validation croisée. Pour des architectures deep learning lourdes (TFT, multimodal), c'est limite mais exploitable avec des stratégies anti-overfitting (régularisation, dropout, early stopping).

15.3 Période 2020-2024 vs plus longue

Période	Avantages	Inconvénients
2015-2024 (10 ans)	+ variabilité climatique	Sentinel-2 démarre 2015, S1 démarre 2014, données Céré'Obs limitées avant
2020-2024 (5 ans) — retenu	Toutes sources cohérentes, S2_SR_HARMONIZED disponible	Échantillon temporel limité
2023-2024 (2 ans)	Données très récentes	Pas assez pour ML

5 ans est le minimum pour avoir une variabilité climatique significative (2020 moyen, 2021 frais, 2022 chaud, 2023 moyen, 2024 humide). C'est aussi la période où toutes nos sources sont alignées en qualité.

15.4 Modalités incluses vs exclues

Modalité considérée	Statut	Justification
NDVI/EVI/NDWI (Sentinel-2)	✓ Include	Standard de la télédétection agricole
VV/VH (Sentinel-1)	✓ Include	Complémente l'optique, tout-temps
Sol (SoilGrids)	✓ Include	Variable explicative essentielle
Météo (NASA POWER)	✓ Include	Driver principal de la phénologie
Topographie (SRTM)	✗ Exclude	CVL très plate, faible variabilité altitude
MODIS (250 m)	✗ Exclude	Résolution insuffisante pour parcellaire
Données agriculteurs	✗ Exclude	Privées, non scalables
Données satellitaires payantes (Planet)	✗ Exclude	Coût, pas open data

15.5 Cible régionale vs parcellaire

Compromis majeur du projet : la cible (date de récolte 50 %) est **régionale**, ce qui crée une asymétrie : on a 1500 observations d'entrée (parcellaires), mais seulement 5 cibles distinctes (une par année).

Limites :

- Le modèle apprend des patterns d'année, pas vraiment de parcelle
- L'évaluation cross-validation doit se faire **par année** (group k-fold), pas en random split
- Avec 5 cibles, on est limité à des validation 5-fold leave-one-year-out

Bénéfices malgré tout :

- Les features parcellaires capturent l'**hétérogénéité spatiale** qui module le timing
- Une parcelle en sol limoneux profond et une en sol sableux n'ont pas la même date optimale même la même année
- L'agrégation à la cible régionale lisse cette variation, mais elle reste partiellement détectable

Pistes futures : obtenir des dates parcellaires de récolte via des partenariats coopératives agricoles (Dijon Céréales, Axérial, etc.) ou via une détection automatique S1/S2 pour générer une cible parcellaire synthétique.

PARTIE V — Validation et qualité

16. Validations effectuées

Cette section synthétise toutes les validations menées sur le jeu de données acquis.

16.1 Validation cible (Céré'Obs)

Contrôle	Méthode	Résultat
Plage des dates	$183 \leq \text{DOY} \leq 199$	✓ Conforme au calendrier blé d'hiver
Variabilité inter-annuelle	Écart max - min = 16 jours	✓ Cohérent avec littérature (10-20j)
Cohérence climatique	2021 (printemps frais) = retard, 2022 (canicule mai) = avance	✓ Logique agronomique
Comparaison historique	Récolte 2020-2024 alignée avec Agreste	✓ Concordance

16.2 Validation RPG

Contrôle	Méthode	Résultat
Indépendance temporelle	Calcul rotation culturale	17,1 % persistance ✓ Bon
Surface min respectée	$\text{min}(\text{surf_parc}) \geq 1.0$	✓ 1.0 ha
Couverture des départements	Histogramme par dpt	✓ 6 départements représentés
Coordonnées WGS84 valides	Étendue lat/lon	✓ Dans bbox CVL
Reproductibilité	Re-tirage avec seed=42	✓ Échantillon identique

16.3 Validation NASA POWER

Contrôle	Méthode	Résultat
T_moyenne annuelle	Comparaison Météo-France	11,5 °C vs ~11 °C ✓
Pluviométrie	Comparaison normales 1981-2010	650 mm/an ✓
ET0 (post-correction)	Comparaison FAO	1000 mm/an ✓
GDD cumul à fin juin	Référence Arvalis	~2000 °C·j ✓
Cohérence inter-départements	Profiles saisonniers similaires	✓ Variations < 10 %

16.4 Validation SoilGrids

Contrôle	Méthode	Résultat
Texture (argile/limon/sable)	Comparaison INRAE-BDAT	Plages cohérentes ✓
pH	Plage 5.5-7.5 attendue blé	Médiane 6.7 ✓
Profils profondeur	Variations cohérentes 0-5 → 15-30	✓
NoData géré	Imputation par voisin	✓ 2 parcelles, distance < 0.5 km

16.5 Validation Sentinel-2

Contrôle	Méthode	Résultat
Plages NDVI par stade	Tableau comparaison phénologie	Toutes valides ✓

Pic NDVI	0.80 - 0.90 en mai attendu	0.84 médian 
Outliers EVI	Filtrage $ EVI < 1.5$	0.12 % outliers  Mineur
NaN pattern	Concentré décembre-février	 Conforme nuages hiver
Corrélation NDVI/NDWI	$r = 0.93$	 Multicolinéarité connue
Cohérence années	Profils saisonniers similaires	 Avec décalages annuels attendus

16.6 Validation Sentinel-1 SAR

Contrôle	Méthode	Résultat
Plages VV (-15 à -5 dB)	Médiane -10.7 dB	 Plage blé
Plages VH (-22 à -12 dB)	Médiane -18.5 dB	 Plage blé
VH < VV	Différence positive	 Toujours
Signature en U inversé	VV : sol nu → canopée → sol nu	 Conforme
Remontée post-récolte	Ratio VV/VH +1.5 dB juillet	 Visible
Densité scènes/parcelle	Médiane 100, max 124	 2.4× Sentinel-2

17. Indicateurs de qualité du dataset

17.1 Tableau de bord global

PARCELLES	SOURCES	DATASETS KAGGLE	VOLUME TOTAL
1 500	6 / 6	6 / 6	~620 Mo

17.2 Indicateurs par source

Source	Complétude	Validation agronomique	Tests effectués
Céré'Obs	5/5 (100%)	✓ Plages, variabilité	4
RPG	1500/1500 (100%)	✓ Échantillonnage validé	5
NASA POWER	10596/10596 (100%)	✓ Toutes valeurs cohérentes	5
SoilGrids	1500/1500 après imputation (100%)	✓ Textures conformes INRAE	4
Sentinel-2	74% sur composites 15j	✓ Profils NDVI valides	6
Sentinel-1	20% structurel (footprint)	✓ Signature SAR valide	6

17.3 Indicateur de réutilisabilité

Critère FAIR	Statut	Mise en œuvre
Findable	✓	Datasets Kaggle indexés Google, mots-clés
Accessible	✓	Téléchargement direct sur Kaggle, gratuit
Interoperable	✓	CSV/GeoJSON standards, UTF-8, WGS84
Reusable	✓	CC BY 4.0, documentation 19 PDFs

18. Limitations connues du dataset

Pour une utilisation honnête et éclairée du jeu de données, voici les limitations identifiées :

18.1 Limitations structurelles

- L1 — Cible régionale, pas parcellaire** : les 1500 parcelles partagent seulement 5 valeurs distinctes de cible (une par année). Cela limite la capacité du modèle à prédire à l'échelle parcellaire fine. *Mitigation* : les features parcellaires apportent toutefois de l'information sur l'hétérogénéité.
- L2 — Échantillon limité à 5 années** : peu pour capturer la variabilité climatique à long terme. Une année extrême (canicule 2003, sécheresse 2018) n'est pas représentée. *Mitigation* : la période 2020-2024 inclut tout de même 5 années climatiquement distinctes.
- L3 — Couverture géographique limitée (CVL)** : les modèles entraînés ne se généraliseront pas automatiquement à d'autres régions (Méditerranée, Atlantique nord, etc.). *Mitigation* : la méthodologie est scalable, le pipeline peut être réutilisé.
- L4 — Pas de données agriculteurs** : variété, date de semis, fertilisation absentes. Ces informations expliqueraient une partie de la variabilité parcellaire restante. *Mitigation* : choix méthodologique assumé pour la reproductibilité et la scalabilité.

18.2 Limitations techniques

- L5 — Couverture S2 dégradée en hiver** : 50-70 % de scènes invalides en décembre-février. *Mitigation* : S1 SAR comble les trous.

L6 — Résolution NASA POWER (0.5°) : la météo est attribuée par département, pas par parcelle. *Mitigation* : dans une région homogène comme la CVL, l'erreur est limitée. Pour une extension future, envisager ERA5 (0.25°) ou Météo-France stations (~5 km).

L7 — Résolution SoilGrids (250m) : les variations intra-parcelles de sol ne sont pas capturées. *Mitigation* : pour des parcelles de 1+ ha, 250m est une résolution acceptable.

L8 — Composite EVI peut diverger : 0,12 % d'outliers à filtrer manuellement. *Mitigation* : documenté, filtre $|EVI| < 1.5$ recommandé.

L9 — Corrélation NDVI/NDWI ($r=0.93$) : redondance d'information. *Mitigation* : problématique pour modèles linéaires, pas pour arbres ni NN. Utiliser PCA ou feature selection si besoin.

18.3 Limitations à venir (phase ML)

- 1500 observations est limite pour deep learning lourd (TFT). Risque d'overfitting à anticiper.
- Validation croisée stricte par année (leave-one-year-out) → 5 folds seulement.
- L'interprétation des résultats sera contrainte par la nature régionale de la cible.

PARTIE VI — Prochaines étapes

19. Construction du master dataset

19.1 Étape 1 — Calcul des features dérivées

À partir des séries temporelles brutes, calculer les ~150 features dérivées définies dans la spécification du Master Data Dictionary :

Famille	Nombre de features	Effort estimé
Sentinel-2 (peak_doy, senescence_doy, intégrales, statistiques mensuelles)	~25	1-2 jours
Sentinel-1 (vv_min_doy, ratio_recovery_doy, amplitudes)	~25	1-2 jours
Météo (GDD à plusieurs dates, cumuls AMJ, jours chauds)	~40	1 jour
Sol (déjà statique, 39 features SoilGrids)	39	—
Métadonnées et flags qualité	~10	0.5 jour
TOTAL features	~140	4-5 jours

19.2 Étape 2 — Fusion finale

Fusionner tous les blocs de features en un master dataset unique :

1. Charger les 6 sources raw
2. Calculer les features dérivées par bloc (pandas, numpy)
3. Joindre par `parcelle_uid` (sol, S2, S1, météo, cible)
4. Vérifier 1500 lignes × ~150 colonnes
5. Exporter en CSV et Parquet
6. Publier comme 7ème dataset Kaggle : **"Master Dataset"**

19.3 Étape 3 — Documentation du master

Produire deux documents finaux :

- **Master Dataset Data Dictionary v2** : avec toutes les features dérivées finalisées
- **Master Dataset Report v2** : version étendue de ce document, intégrant phase 4 + 5

20. Approche ML prévue

20.1 Stratégie de modélisation

Plusieurs familles de modèles seront comparées, avec une logique de **complexité croissante** :

Phase	Modèles	Objectif
P1 — Baseline	Mean predictor, régression linéaire	Établir le plancher de performance
P2 — ML classique	Random Forest, XGBoost, LightGBM	Modèles tabulaires interprétables, baseline solide
P3 — Séquentiel	LSTM, GRU avec features S2/S1 brutes	Exploitation des séries temporelles
P4 — Avancé	Temporal Fusion Transformer (TFT)	State-of-the-art pour séries multivariées
P5 — Multimodal	Architecture custom fusionnant S2 + S1 + tabulaire	Exploiter pleinement la richesse multi-source

20.2 Stratégie d'évaluation

Cross-validation : Leave-One-Year-Out (LOYO) avec les 5 années comme folds.

- Train sur 4 années, test sur 1 année
- Répété 5 fois
- Métriques : RMSE, MAE, R^2 sur DOY de récolte prédit

Justification : évite les fuites temporelles. C'est aussi le scénario réel d'usage opérationnel.

20.3 Interprétabilité

Au-delà des performances pures, l'analyse d'**importance des features** est cruciale :

- **SHAP values** pour XGBoost et Random Forest
- **Attention weights** pour Transformer (TFT)
- **Permutation importance** pour identifier les features clés
- **Partial dependence plots** pour comprendre les effets non linéaires

Cela permettra de répondre aux questions de recherche : "Quels signaux sont les plus prédictifs ? S2 ? S1 ? Sol ? Météo ?"

21. Conclusion et perspectives

21.1 Ce qui a été accompli

À ce stade du projet (fin de la phase d'acquisition) :

- ☒ **6 sources de données** intégrées, validées et publiées
- ☒ **1500 parcelles** de blé en CVL sur 5 années
- ☒ **~620 Mo** de données structurées, accessibles publiquement
- ☒ **19 documents PDF** documentant la méthodologie
- ☒ **Bugs critiques** identifiés et corrigés (ET0, GEE empty windows)
- ☒ **Optimisations majeures** (SoilGrids WCS 91× plus rapide)
- ☒ **Validation agronomique** sur toutes les sources (plages, signatures)

21.2 Ce qui reste à faire

- ☐ Construction du master dataset (features dérivées + fusion) — 4-5 jours
- ☐ Entraînement des modèles ML (5 phases) — 3-4 semaines
- ☐ Analyse d'interprétabilité (SHAP, attention) — 1-2 semaines
- ☐ Dashboard de visualisation (Streamlit) — 1 semaine
- ☐ Rédaction du mémoire final — 4-6 semaines
- ☐ Soutenance

21.3 Perspectives à plus long terme

Au-delà du mémoire :

- **Publication "data paper"** dans Scientific Data (Nature) ou ESSD (Copernicus) — le caractère original (premier dataset public multi-source à l'échelle parcellaire en France) justifie une publication
- **Extension à d'autres régions** (Picardie, Champagne, Aquitaine) → tester la généralisabilité
- **Extension à d'autres cultures** (colza, orge, maïs)
- **Collaboration avec coopératives** pour obtenir des dates de récolte parcellaires réelles
- **Dashboard opérationnel** pour agriculteurs ou coopératives

21.4 Mot final

Ce projet de mémoire représente plusieurs mois de travail méthodique sur des données complexes et hétérogènes. Au-delà du résultat ML final, sa principale contribution scientifique est **l'ouverture publique d'un jeu de données multi-source unique**, accompagné d'une documentation exhaustive qui en permettra la réutilisation par la communauté.

L'expérience accumulée — bugs, optimisations, décisions, compromis — est elle-même un actif précieux, capitalisé dans ce rapport pour servir aux futurs étudiants et chercheurs travaillant sur des projets similaires de télédétection agricole.

Citation recommandée :

Kassi R. (2025). *Master Dataset Report: Multi-source Sentinel-1/2 + climate + soil dataset for winter wheat harvest prediction in Centre-Val de Loire, France (2020-2024)*. Master's thesis methodology report, Indrashil University. Encadrants : Dr. V. Thakar, Dr. D. Ammar. Available on Kaggle: kaggle.com/rgislkassi